

# Modellierung und echtzeitfähiges Tracking befahrbbarer Flächen unter Verwendung von Stereo-Kameras

Diplomarbeit  
von

cand. mach. Malte Joos

An der Fakultät für Maschinenbau  
Institut für Mess- und Regelungstechnik

Betreuer: Prof. Dr.-Ing. Christoph Stiller  
Betreuernder Mitarbeiter: Dipl.-Ing. Benjamin Ranft

Bearbeitungszeit: 01. April 2011 – 30. September 2011

## Aufgabenstellung

Für viele moderne Fahrerassistenzsysteme – etwa zur Erhöhung der Aktiven Sicherheit durch automatisches Notbremsen, aber auch im Komfortbereich – sind ein räumliches Abbild der Fahrzeugumgebung sowie eine Erkennung der Fahrbahn darin von essentieller Bedeutung. Zur Bestimmung dieser Informationen werden in zunehmendem Maße stereoskopische Kamerasysteme verwendet, welche im Vergleich zu Radargeräten einige Vorteile bieten. Allerdings stellen diese aufgrund großer Datenmengen höhere Anforderungen an die Effizienz der darauf aufbauenden Algorithmen und Implementierungen.

Im Rahmen dieser Diplomarbeit soll ein Verfahren zur Detektion der Fahrbahn auf Basis eines Stereokamerasystems konzipiert und umgesetzt werden. Dieses soll qualitativ zur Generierung einer Höhenkarte relativ zur Fahrbahn geeignet sein und dementsprechend gut in der Praxis auftretende Längsprofile und Rollwinkel modellieren können. Für den Einsatz im Versuchsfahrzeug ist Echtzeitfähigkeit erforderlich, welche ggf. durch Parallelisierung und Vektorisierung erreicht werden soll. Wünschenswert ist ebenso eine ressourcenschonende Implementierung zugunsten des vorhandenen Verfahrens zur räumlichen Rekonstruktion aus Stereo-Aufnahmen. Dieses liefert als Eingangsdaten dichte Disparitätsbilder, gegenüber deren Rauschen und Lücken das zu entwickelnde Verfahren robust sein soll.

Im einzelnen sind folgende Punkte zu bearbeiten:

- Literaturrecherche und Einarbeitung mit den Schwerpunkten
  - geeignete Ansätze zur Modellierung der Fahrbahn
  - robuste Schätzverfahren und zeitliche Verfolgung
  - Ansätze zur Optimierung von Laufzeit und Ressourcenbedarf
- Modellierung und Tracking der Fahrbahn
  - Konzeption eines kamera-nahen Verfahrens gemäß der o. g. Qualitätsanforderungen in MATLAB
  - Portierung des Verfahrens nach C++ und Realisierung der o. g. Effizienzanforderungen durch Parallelisierung und Vektorisierung
- Evaluation und Diskussion
  - qualitative Bewertung und Verbesserung des Verfahrens mittels institutseigenen Bildsequenzen
  - detaillierte Analyse und Optimierung der Laufzeiten einzelner Verarbeitungsschritte

## **Erklärung**

Ich versichere, die vorliegende Arbeit selbstständig und nur mit den im Literaturverzeichnis angegebenen Quellen und Hilfsmitteln angefertigt zu haben.

---

Karlsruhe, den 30.09.11

## **Unterschrift der Betreuer**

Betreuer:

---

Prof. Dr.-Ing. Christoph Stiller

Betreuernder Mitarbeiter:

---

Dipl.-Ing. Benjamin Ranft

## **Kurzfassung**

Es wird ein Verfahren zur nicht-ebenen Modellierung des Fahrbahn-Längsprofils im Vorfeld eines Fahrzeugs entworfen. Ausgehend von einem Disparitätenbild erfolgt die Modellierung in der *V-Disparität* unter Verwendung uniformer kubischer B-Splines. Die Modellparameter werden zeitlich mit einem *Kalman Filter* verfolgt. Das Ergebnis des Verfahrens ist ein Modell des Fahrbahnprofils in Kamerakoordinaten, und darauf aufbauend eine Höhenkarte der Umgebung relativ zum Fahrbahniveau. Das entstandene System ist echtzeitfähig und wird durch reale Testfahrten verifiziert.

## **Abstract**

A new method for non-flat modeling of the longitudinal road profile in front of a vehicle is proposed. Based on a disparity image the profile is modeled in *V-Disparity* space by using uniform cubic B-Splines. The model is tracked over time using a *Kalman Filter*. The result is a model of the road profile in camera coordinates, and based on it an elevation map of the environment relative to the road surface. The proposed system is real-time capable and is verified by real test runs.

# Inhaltsverzeichnis

<b>1 Einleitung</b>	<b>1</b>
1.1 Problemstellung und Motivation . . . . .	2
1.1.1 Einordnung . . . . .	2
1.1.2 Problemstellung . . . . .	2
1.2 Entwickeltes Verfahren . . . . .	2
1.2.1 Verwendung . . . . .	3
1.3 Gliederung der Arbeit . . . . .	3
<b>2 Stand der Technik</b>	<b>4</b>
2.1 Fahrbahnschätzung . . . . .	4
2.2 Anwendung in Fahrerassistenzsystemen . . . . .	5
<b>3 Theoretische Grundlagen</b>	<b>6</b>
3.1 Disparität . . . . .	6
3.1.1 V-Disparität . . . . .	7
3.1.2 U-Disparität . . . . .	8
3.2 Splines . . . . .	8
3.3 B-Splines . . . . .	9
3.4 Uniforme Kubische B-Splines . . . . .	9
3.4.1 Herleitung einer Matrix-Darstellung . . . . .	10
3.4.2 Randbedingungen . . . . .	12
3.5 Mathematische Schätzverfahren . . . . .	13
3.5.1 Methode der kleinsten Fehlerquadrate . . . . .	13
3.5.2 Weighted Least Squares . . . . .	14
3.5.3 M-Estimator . . . . .	14
3.5.4 Kalman Filter . . . . .	15
3.5.5 Informationsfilter . . . . .	16
<b>4 Umsetzung</b>	<b>18</b>
4.1 Überblick . . . . .	18
4.2 Module . . . . .	18
4.2.1 Rollwinkelkompensation . . . . .	18
4.2.2 Beachtung des Fahrkorridors . . . . .	20
4.2.3 Vertikaler Hindernisfilter . . . . .	21
4.2.4 Gewichtung der V-Disparität . . . . .	22
4.2.5 Übertragung der V-Disparität in die Messgleichung . . . . .	24
4.2.6 Gewichtung der Messgleichungen . . . . .	26
4.2.7 Kalman Filterung des Splines . . . . .	27
4.2.8 Erstellung des Straßenprofils . . . . .	29
4.2.9 Konstruktion der Höhenkarte . . . . .	30
4.3 Implementierung . . . . .	30

<b>5 Ergebnis</b>	<b>32</b>
5.1 Qualitative Bewertung der Fahrbahnschätzung . . . . .	32
5.1.1 Rollwinkelkompensation . . . . .	34
5.2 Laufzeituntersuchung . . . . .	34
5.2.1 Laufzeituntersuchung nach dem Amdahlschen Gesetz . . . . .	35
5.3 Bewertung . . . . .	37
<b>6 Zusammenfassung</b>	<b>39</b>
<b>7 Ausblick</b>	<b>40</b>
7.1 Verbesserungspotentiale . . . . .	40
7.1.1 Erweiterung der Filter für die V-Disparität . . . . .	40
7.1.2 Kalman Prädiktion auch beim Abbiegen . . . . .	41
7.2 Mögliche Weiterentwicklung . . . . .	42
7.2.1 Weiche Übergänge statt Grenzwerte im Disparitätenbild . . . . .	42
7.2.2 Modellierung der Systemdynamik für das Kalman Filter . . . . .	42
7.2.3 Optimierung durch weitergehende Parallelisierung . . . . .	42
<b>Verwendete Symbole</b>	<b>45</b>
<b>Abbildungsverzeichnis</b>	<b>46</b>
<b>Literaturverzeichnis</b>	<b>46</b>

# 1. Einleitung

Fahrerassistenzsysteme sind fester Bestandteil der heutigen Fahrzeuggeneration und gewinnen immer mehr an Bedeutung. Allgemein werden sie in drei Bereichen eingesetzt: Erhöhung der Sicherheit, Steigerung des Fahrkomforts und Verbesserung der Ökonomie.

Der wichtigste Teil ist dabei die Erhöhung der Sicherheit im Straßenverkehr. Neben herkömmlichen Systemen wie dem *Anti-Blockier-System (ABS)* und dem *Elektronischen-Stabilitäts-Programm (ESP)* gibt es heute bereits eine Vielzahl weiterer Systeme die in modernen Fahrzeugen zum Einsatz kommen. Der *Spurverlassenswarner* warnt den Fahrer beim ungewollten Verlassen der Fahrbahn. Beim *Adaptive-Cruise-Control (ACC)* regelt das Fahrzeug automatisch einen geschwindigkeitsabhängigen Abstand zum voraus fahrenden Fahrzeug ein.

Das *ACC* hat gleichermaßen eine Komfortfunktion, da es den klassischen Tempomat erweitert. Andere Systeme zur Erhöhung des Fahrkomforts sind (autonome) Einparkhilfen oder das aktive Anpassen des Fahrwerks an Fahrbahnunebenheiten um Aufbauschwingungen zu dämpfen.

Zur Verbesserung der Ökonomie werden Systeme entwickelt die die Fahrzeugführung hinsichtlich eines geringeren Verbrauchs beeinflussen. So wird für Automatikgetriebe der optimale Gang für ein gefordertes Moment eingelegt oder die verbrauchsärmste Beschleunigung bzw. Verzögerung hinsichtlich der Verkehrssituation vorgegeben.

Alle Systeme benötigen dabei eine intelligente Wahrnehmung des Fahrzeugzustandes und der Fahrzeugumgebung. Um dies zu ermöglichen verfügen moderne Assistenzsysteme über eine große Anzahl unterschiedlicher Sensoren wie Radar oder Kamerasysteme. Die zunehmende Komplexität der Fusion und Interpretation der Sensordaten verlangt neuartige Algorithmen und Modelle zur echtzeitfähigen Verarbeitung der gelieferten Daten. Das Ziel dabei ist es ein möglichst exaktes Abbild des Fahrzeugzustandes und seines Umfeldes zu erhalten. Auf der gewonnenen Basis lässt sich dann eine Vielzahl von Fahrerassistenzsystemen entwickeln die den Fahrer in vielerlei Hinsicht bei seiner Fahraufgabe unterstützen.

Die entstehenden Systeme werden dabei immer intelligenter und entwickeln sich von rein passiven Assistenzfunktionen hin zu einem autonomen Fahrzeug.

## 1.1 Problemstellung und Motivation

### 1.1.1 Einordnung

Ein wichtiger Bestandteil vieler Fahrerassistenzsysteme ist die Modellierung der Fahrzeugumgebung. Im Speziellen geht es dabei um die Interpretation der Verkehrssituation vor dem Fahrzeug. Dies beinhaltet unter anderem die Segmentierung der Straße, von Fahrzeugen, festen Hindernissen und Fußgängern.

Die Segmentierung wird häufig auf einem 3D-Modell der Fahrzeugumgebung durchgeführt welches von Sensoren wie z.B. Radar, Stereo-Kamera-Systemen oder 3D-Laserscannern erstellt wird. Um genaue Aussagen über die Position eines anderen Verkehrsteilnehmers oder eines Hindernisses treffen zu können benötigt man ein exaktes Modell der Fahrbahnoberfläche. Zu deren Modellierung wird dabei in vielen Ansätzen von einer ebenen Fläche ausgegangen was in Wirklichkeit jedoch häufig nicht der Fall ist.

### 1.1.2 Problemstellung

Ein ebenes Modell zur Beschreibung der Fahrbahnoberfläche ist nur bedingt geeignet, da es in vielen Fällen die tatsächlichen Gegebenheiten nur ungenügend beschreibt. So kann eine Erhebung des Straßenverlaufs als Hindernis wahrgenommen werden, oder eine Absenkung des Straßenverlaufs dazu führen, dass Fahrzeuge übersehen werden. Abbildung 1.1 zeigt diesen Sachverhalt schematisch.

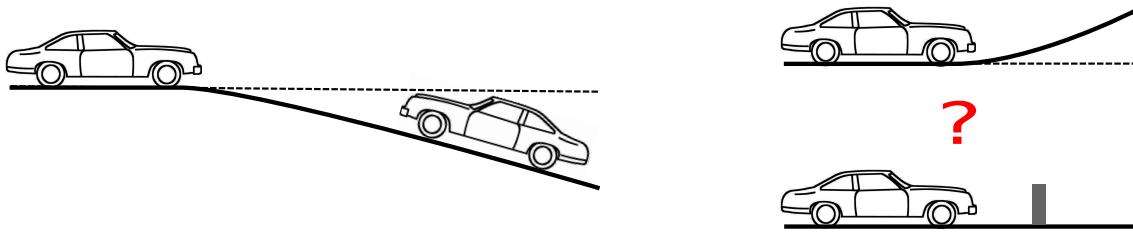


Abbildung 1.1: Ebener und tatsächlicher Fahrbahnverlauf.

Um präzisere Aussagen über die Fahrbahn und auf ihr befindlichen Objekte treffen zu können wird im Zuge dieser Arbeit ein Verfahren zur Modellierung des Fahrbahnverlaufs vorgestellt das nicht der Einschränkung einer ebenen Fahrfläche unterliegt.

## 1.2 Entwickeltes Verfahren

Das in dieser Arbeit entwickelte System (vgl. Bild 1.2) erstellt und verfolgt ein Modell der befahrbaren Fläche im Vorfeld des Fahrzeugs.

Als Eingangsdaten benötigt es ein Disparitätenbild (vgl. Abschnitt 3.1) sowie eine Eigenbewegungsschätzung. Das Ergebnis des Verfahrens ist eine Höhenkarte der Punkte der Umgebung relativ zum Fahrbahnprofil sowie eine Segmentierung der befahrbaren Fläche.

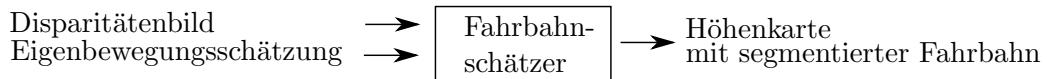


Abbildung 1.2: Fahrbahnschätzer

Das Längsprofil der Fahrbahn wird in der *V-Disparität* (vgl. Abschnitt 3.1.1) mit Hilfe kubischer Splines (vgl. Abschnitt 3.2) modelliert. In Querrichtung zur Eigenbewegung wird

das Fahrbahnprofil als konstant angenommen.

Mit Hilfe der Eigenbewegungsschätzung werden die gewonnenen Modellparameter mit einem Kalman Filter zeitlich verfolgt.

### 1.2.1 Verwendung

Verwendung findet das entwickelte System am Forschungszentrum Informatik (FZI)<sup>1</sup> sowie dem Institut für Mess- und Regelungstechnik<sup>2</sup> in Karlsruhe. Dort wird es als separates Softwaremodul in die Stereo-Verarbeitungskette im Fahrzeug eingebettet.

Ein Stereo-Kamerasystem nimmt die Umgebung im Vorfeld des Fahrzeugs auf. Aus den Eingangsbildern wird durch Stereo-Matching ein Tiefenbild erzeugt [RSK11] und die Eigenbewegung geschätzt [GZS11].

Aus dem Tiefenbild und der Eigenbewegungsschätzung erstellt das in dieser Arbeit vorgestellte Verfahren eine Höhenkarte der Umgebung, und bildet somit die Grundlage weiterer Funktionsentwicklungen. Im Rahmen einer ersten konkreten Anwendung dient es zur Erhöhung der Robustheit eines vorhandenen Systems zur Erkennung der Fahrspur anhand von Fahrbahnmarkierungen.

## 1.3 Gliederung der Arbeit

Neben der Einleitung durch dieses Kapitel ist die Diplomarbeit folgendermaßen gegliedert. In Kapitel 2 wird zunächst der Stand der Technik dargelegt. Neben der Vorstellung interessanter Ansätze für die Fahrbahnschätzung aus dem Forschungsumfeld wird auch deren Verwendung in modernen Fahrerassistenzsystemen aufgezeigt. Kapitel 3 behandelt alle nötigen Grundlagen die bei der Fahrbahnschätzung verwendet werden. Neben dem eigentlichen Modell beinhaltet dies auch die Abhandlung wichtiger mathematischer Verfahren zur Parameterschätzung. Darauf aufbauend wird in Kapitel 4 das gesamte Verfahren der Fahrbahnschätzung detailliert beschrieben. In Kapitel 5 werden die Ergebnisse des Verfahrens dargestellt und bewertet. Dies beinhaltet auch eine Laufzeituntersuchung. Kapitel 6 fasst den entwickelten Fahrbahnschätzer zusammen. Zum Schluss folgt in Kapitel 7 ein Ausblick der sowohl Verbesserungspotentiale des bisherigen Verfahrens aufzeigt, als auch grundlegende Erweiterungen der Fahrbahnschätzung vorstellt.

---

<sup>1</sup><http://www.fzi.de>

<sup>2</sup><http://www.mrt.kit.edu>

## 2. Stand der Technik

### 2.1 Fahrbahnschätzung

In [LAT02] wird zur Modellierung der Fahrbahnoberfläche das so genannte *V-Disparitäts-Histogramm* eingeführt. Dabei wird über die Bildzeilen eines Disparitätenbildes ein Histogramm erzeugt. In dem V-Disparitäts-Histogramm bildet sich die Fahrbahnoberfläche als Linie ab. Im Falle einer flachen Oberfläche (wie hier angenommen) wird diese Linie zu einer Geraden und wird mit Hilfe der *Hough-Transformation* detektiert. Weiterhin wird hier auch eine nicht-flache Oberfläche durch stückweise definierte Geraden modelliert.

[WBR<sup>+</sup>09] und [LF10] verwenden B-Splines zur Modellierung des Längsprofils der Fahrbahn. Die B-Spline Parameter werden aus 3D-Messungen (von Stereo-Kameras) der Umgebung geschätzt und mit Hilfe eines Kalman Filters zeitlich verfolgt.

Darauf aufbauend wird in [WBR<sup>+</sup>09] ein Algorithmus zur Segmentierung von Straße und Hindernissen vorgestellt. In [LF10] wird links und rechts des Fahrzeugs ein B-Spline-Verlauf der Fahrbahn geschätzt und damit der Rollwinkel der Straße bestimmt. Außerdem wird das häufig verwendete Klothoidenmodell zur Beschreibung des Querverlaufs der Fahrbahn mit einem B-Spline Modell zur Beschreibung des Längsprofils kombiniert. Das so erhaltene Modell bietet eine exakte Repräsentation des Fahrbahnverlaufs sowohl in Längs- als auch in Querrichtung.

In [ONMT07] werden die 3D-Daten eines Stereo-Kamerasystems in eine initiale Höhenkarte bezüglich des Fahrzeugs transformiert und daraus mit Hilfe des *RANSAC* Verfahrens in der Nähe des Fahrzeugs eine quadratische Oberfläche geschätzt. Die dabei verwendeten Messpunkte werden dann durch einen *Region Growing* Algorithmus stetig erweitert und die Oberfläche neu geschätzt. Im Anschluss findet eine Klassifizierung der Messdaten in Fahrbahn, Hindernis und Verkehrsinsel statt.

In [ZY07] wird ein Verfahren zur Fahrbahnmodellierung auf Basis von *Fuzzy Clustering* vorgestellt das selbst mit stark verrauschten Messdaten zurecht kommt. Dabei werden die Normalenvektoren lokaler Ebenen in den Messdaten geschätzt. Mit Hilfe von *Fuzzy Clustering* wird dann der Mittelwert aller lokalen Normalenvektoren ermittelt und damit eine Ebene, welche die Fahrbahnoberfläche repräsentiert, in die verrauschte Punktwolke gelegt.

In [NDF<sup>+</sup>04] wird ein lineares und ein klothoides Fahrbahnmodell kombiniert. In Fahrzeughöhe wird die Fahrbahn als flach angenommen und daraus der Nickwinkel des Fahrzeugs bestimmt. Für diskrete Modellparameter des Klothoidenmodells wird aus den ent-

ferneren Messpunkten ein Histogramm erstellt und daraus die Parameter, die die Fahrbahn am besten beschreiben, ermittelt. Darauf aufbauend werden dann Hindernisse segmentiert.

## 2.2 Anwendung in Fahrerassistenzsystemen

Auf Grundlage einer robusten Fahrbahnschätzung und der Segmentierung von Hindernissen wurden bereits einige Fahrerassistenzsysteme auf den Markt gebracht.

Daimler bietet mit dem *Active Brake Assist* [AG11a] ein Notbremssystem das die Anzahl und Schwere von Auffahrunfällen verringert. Ist bei unveränderter Fahrweise ein Unfall unvermeidlich wird der Fahrer erst optisch und dann akustisch gewarnt. Verschärft sich die Situation leitet das System eine Teilbremsung ein. Steht die Kollision kurz bevor wird selbstständig eine Vollbremsung eingeleitet, um die Aufprallgeschwindigkeit zu reduzieren. Beim Spurhalte-Assistent von Daimler [AG11b] überwacht eine Kamera hinter der Frontscheibe das korrekte Einhalten der Spur. Das System detektiert wenn der Fahrer unabsichtlich die Fahrspur verlässt und warnt ihn über Vibrationen im Lenkrad.

Audi nutzt das Notbremssystem von Bosch [Gmb11]. Durch die Datenfusion von zwei Fernbereichs-Radarsensoren und einer Videokamera entsteht eine umfassende Interpretation der Verkehrssituation. Bei der Erkennung eines potentiellen Hindernisses baut das Bremsregelsystem einen leichten Bremsdruck auf, um bei einer eventuell folgenden Bremsung sofort verzögern zu können. Nähert sich das Fahrzeug dem Hindernis ohne Reaktion des Fahrers wird eine Teilbremsung eingeleitet und ein akustischer Warnton ausgegeben. Wie bei Daimler führt auch dieses System eine automatische Vollbremsung aus wenn eine Kollision nicht mehr zu verhindern ist.

Wichtiger Bestandteil des *Advanced Pre-Crash Safety-Systems* von Lexus, das ähnlich wie die Systeme von Bosch und Daimler funktioniert, ist das *Objekterkennungssystem* [Lex11]. Zur Umfeldwahrnehmung vereint es Radar-, Infrarot- und Stereokameratechnologien. Dies ermöglicht eine umfassende Detektion und Klassifikation von Hindernissen, ins Besondere auch von Menschen und Tieren.

Auch Volvo integriert in seinem *Collision Warning with Auto Brake* System [CJLL07] Radarsensoren und Kameras zur Umfeldwahrnehmung. Toyota hat ebenfalls ein *Lane Keeping Assist* sowie ein *Pre-Crash Safety System* entwickelt [Toy11].

## 3. Theoretische Grundlagen

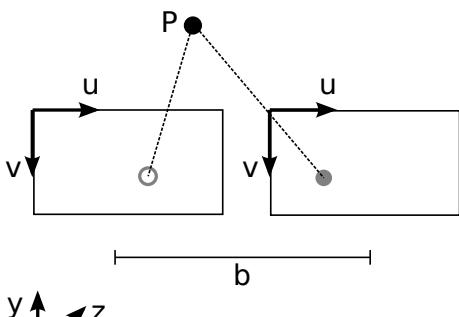
### 3.1 Disparität

Mit Hilfe eines Stereo-Kamerasystems lässt sich ein Tiefenbild der Umgebung erstellen. Eine ausführliche Arbeit zum Thema *Stereo Vision* findet man in [WW98]. Eine kurze Herleitung zur Erzeugung des Tiefenbildes findet sich auch in [LAT02].

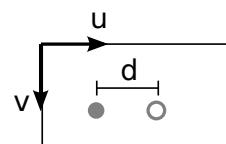
Im Nachfolgenden wird von einem einfachen Lochkameramodell ausgegangen. In der Praxis treten, durch die Verwendung von Objektiven, jedoch Abbildungsverzerrungen auf, die zunächst unter Verwendung geeigneter Modelle korrigiert werden müssen. Ein solches Verfahren ist in [RSK11] beschrieben.

Ein fester Punkt  $P$  in Weltkoordinaten ( $xyz$ ) bildet sich auf Bildebenen verschiedener Kameras unterschiedlich ab. Ist das Stereo-Kamerasystem mit Basisbreite  $b$  parallel ausgerichtet und hat identische Bildebenen so liegt der Punkt  $P$  in beiden Bildern auf einer gemeinsamen Horizontalen (vgl. Abb. 3.1a).

Legt man das Stereo-Bildpaar übereinander so ist der horizontale Abstand der Abbildungen eines bestimmten Punktes  $P$  auf den beiden Bildern die *Disparität*  $d$  (vgl. Abb. 3.1b).



(a) Stereo-Abbildung eines Punktes.



(b) Disparität eines Punktes.

Abbildung 3.1: Erzeugung eines Disparitätsbildes.

Besitzen beide Kameras die gleiche Brennweite  $f$  und beträgt der horizontale Abstand

beider Brennpunkte  $b$ , dann gilt für den Abstand  $z$  eines Punktes  $P$  zur Bildebene:

$$z = \frac{bf}{d}. \quad (3.1)$$

Um die Entfernung eines Punktes  $P$  zu bestimmen genügt es also seine Disparität in einem Stereo-Bildpaar zu ermitteln. Dazu müssen in einem Bildpaar mit Hilfe von Stereo-Match-Algorithmen entsprechende Punkt-Korrespondenzen gefunden werden. Einen Überblick über viele unterschiedliche Verfahren gibt [RSK11],[AA98] und [vdMG06].

Nach Gleichung 3.1 ist die Entfernung eines Punktes vom optischen Zentrum umgekehrt Proportional zu seiner Disparität. Das bedeutet im Speziellen, dass ein Punkt im Unendlichen die Disparität null hat. Ein Punkt auf der Bildebene hat die maximale Disparität und entspricht gerade der Basisbreite  $b$  des Stereo-Kamerasystems ausgedrückt in Pixeln. Abbildung 3.2 zeigt das Disparitätenbild einer Fahrzeugumgebung. Der Grauwert eines Pixels repräsentiert dabei die Disparität eines Punktes: je heller ein Pixel desto größer seine Disparität. Im weiteren Verlauf der Arbeit wird die Disparität eines Punktes im Disparitätenbild mit  $d(u,v)$  referenziert.

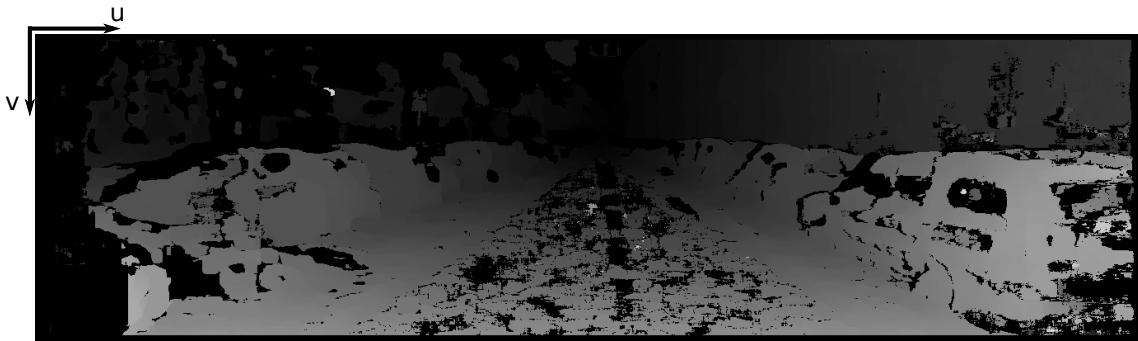


Abbildung 3.2: Disparitätenbild.

### 3.1.1 V-Disparität

Das Längsprofil der Straßenoberfläche wird mit Hilfe der so genannten *V-Disparität* modelliert. Die V-Disparität ist ein Histogramm der Disparitäten über jede Bildzeile eines Disparitätenbildes. Die Modellierung des Straßenprofils mit Hilfe eines solchen Histogramms wurde erstmals in [LAT02] vorgestellt.

Die V-Disparität akkumuliert für jede Bildzeile eines Disparitätenbildes alle Punkte mit der gleichen Disparität (vgl. Abb. 3.3). Die Abszisse der V-Disparität entspricht der Disparität und der Helligkeitswert eines Pixels der Häufigkeit dieser Disparität in der entsprechenden Bildzeile. Das *V-Disparitätenbild* hat demnach genauso viele Zielen wie das Disparitätenbild. Zur besseren Darstellung ist es hier leicht vergrößert dargestellt.

Unter der Voraussetzung dass der Rollwinkel zwischen Fahrzeug und Fahrbahn null ist bildet sich das Längsprofil der Straße in der V-Disparität als scharfe Linie ab. Im Allgemeinen verläuft sie von oberen Bildzeilen mit kleiner Disparität (und damit großer Entfernung) zu den unteren Bildzeilen mit großer Disparität. Im Spezialfall einer ebenen Fahrbahnfläche lässt sich diese Linie als Gerade beschreiben.

Objekte mit senkrechten Flächen und damit potentielle Hindernisse haben in jeder Bildzeile die gleiche Entfernung und damit die gleiche Disparität. Sie bilden sich somit im V-Disparitätenbild als vertikale Linien ab und enden auf der Fahrbahnlinie.

Gemäß des hyperbolischen Zusammenhangs von Entfernung und Disparität nach Gleichung 3.1 fällt die Auflösung der Disparität und Bildzeile mit steigender Entfernung. Dies

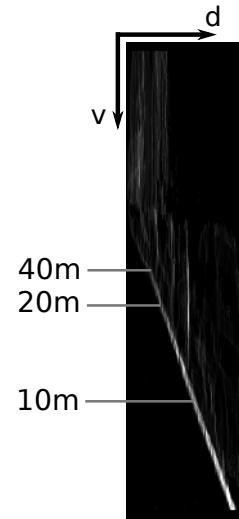


Abbildung 3.3: V-Disparität.

wird durch die in Abbildung 3.3 angebrachte Skala deutlich.

Im weiteren Verlauf der Arbeit wird der Helligkeitswert eines Bildpunktes in der V-Disparität mit  $V(d, v)$  referenziert.

### 3.1.2 U-Disparität

Analog der V-Disparität lässt sich auch die *U-Disparität* erzeugen. Zur Erstellung des Histogramms werden in jeder Bildspalte eines Disparitätenbildes alle Pixel mit der gleichen Disparität akkumuliert. Abbildung 3.4 zeigt die U-Disparität für das in Abbildung 3.2 dargestellte Disparitätenbild.



Abbildung 3.4: U-Disparität.

Helle Punkte in der U-Disparität bedeuten, dass diese Disparität in der entsprechenden Bildspalte häufig vorkommt und sind somit ein eindeutiges Merkmal für vertikale Objekte. Diese Eigenschaft wird dazu genutzt, um das Disparitätenbild zu filtern und Punkte, die nicht zur Fahrbahn gehören, zu verwerfen (vgl. Abschnitt 4.2.3).

Im weiteren Verlauf der Arbeit wird der Helligkeitswert eines Bildpunktes in der U-Disparität mit  $U(u, d)$  referenziert.

## 3.2 Splines

Splines sind stückweise definierte Polynome, die zu einer Kurve zusammengesetzt werden. Jedes Teilstück eines Splines ist dabei von der gleichen Ordnung  $n$ . Die Verbindungspunkte an denen die einzelnen Spline-Stücke zusammengesetzt werden nennt man *Knoten*. Ein Spline der Ordnung  $n$  ist auf seinem gesamten Gültigkeitsbereich  $n-1$  mal stetig differenzierbar. Dies gilt insbesondere auch an seinen Knotenpunkten. Daher gilt an einem Knoten

$\hat{t}$  der benachbarten Spline-Segmente  $S_i$  und  $S_{i+1}$ :

$$S_i(\hat{t}) = S_{i+1}(\hat{t}) \quad (3.2)$$

$$S'_i(\hat{t}) = S'_{i+1}(\hat{t}) \quad (3.3)$$

⋮

$$S_i^{(n-1)}(\hat{t}) = S_{i+1}^{(n-1)}(\hat{t}). \quad (3.4)$$

Mit Hilfe von Splines lassen sich, im Vergleich zu Polynomen höherer Ordnung, komplexe Formen relativ einfach mathematisch beschreiben. Daher sind sie heute in vielen Bereichen weit verbreitet.

### 3.3 B-Splines

Jeder Spline einer festen Ordnung und Glätte lässt sich als Linearkombination von Basis-Splines der gleichen Ordnung und Glätte darstellen [De 01]. Die daraus entstehenden Splines werden *B-Splines* genannt. Eine B-Spline Kurve der Ordnung  $n$  hat die Form

$$S(t) = \sum_i N_i^n(t) c_i, \quad (3.5)$$

mit den *Kontroll-* oder *de Boor Punkten*

$$c = [c_1 \dots c_n]^\top. \quad (3.6)$$

Die Basis-Splines  $N_i^j(t)$  werden ausgehend von einem Knotenvektor  $\mathbf{T} = [t_0 \dots t_i]$ ,  $t_i < t_{i+1}$  nach der *Cox- de Boor Rekursionsgleichung* definiert [BBB87]:

$$N_i^0(t) = \begin{cases} 1 & \text{wenn } t \in [t_i, t_{i+1}) \\ 0 & \text{sonst} \end{cases} \quad (3.7)$$

$$N_i^j(t) = \frac{t - t_i}{t_{i+j} - t_i} N_i^{j-1}(t) + \frac{t_{i+j+1} - t}{t_{i+j+1} - t_{i+1}} N_{i+1}^{j-1}(t). \quad (3.8)$$

Diese Funktionen bilden die Basis für den Vektorraum der stückweisen Polynome. Das bedeutet, sie sind linear unabhängig und jede mögliche B-Spline Kurve lässt sich als Linearkombination dieser Basis-Splines ausdrücken. Die Faktoren der Linearkombination entsprechen dabei den Kontrollpunkten  $c$ .

### 3.4 Uniforme Kubische B-Splines

Kubische Splines bestehen aus Polynomen dritter Ordnung. Sie eignen sich besonders, da ein kubisches Polynom einfach zu berechnen ist, aber dennoch flexibel genug, um damit komplexe Formen darstellen zu können. Durch ihre zweifach stetige Differenzierbarkeit bilden sie außerdem die Eigenschaft der stetigen Vertikalgeschwindigkeit im Straßenbau ab. Splines deren Knotenpunkte  $\mathbf{T}$  auf dem gesamten Gültigkeitsbereich äquidistant angeordnet sind nennt man *uniform*. Die Basis der uniformen kubischen Splines  $N_i^3(t)$ ,  $i \in 1, 2, 3, 4$  ist eindeutig definiert und für jedes Segment  $i$  des Splines identisch. Die Form der uniformen kubischen Splines wird somit nur durch seine Kontrollpunkte  $c$  bestimmt. Abbildung 3.5 zeigt einen uniformen kubischen Spline mit seinen Knoten.

Die Basis der uniformen kubischen B-Splines lässt sich direkt bestimmen.

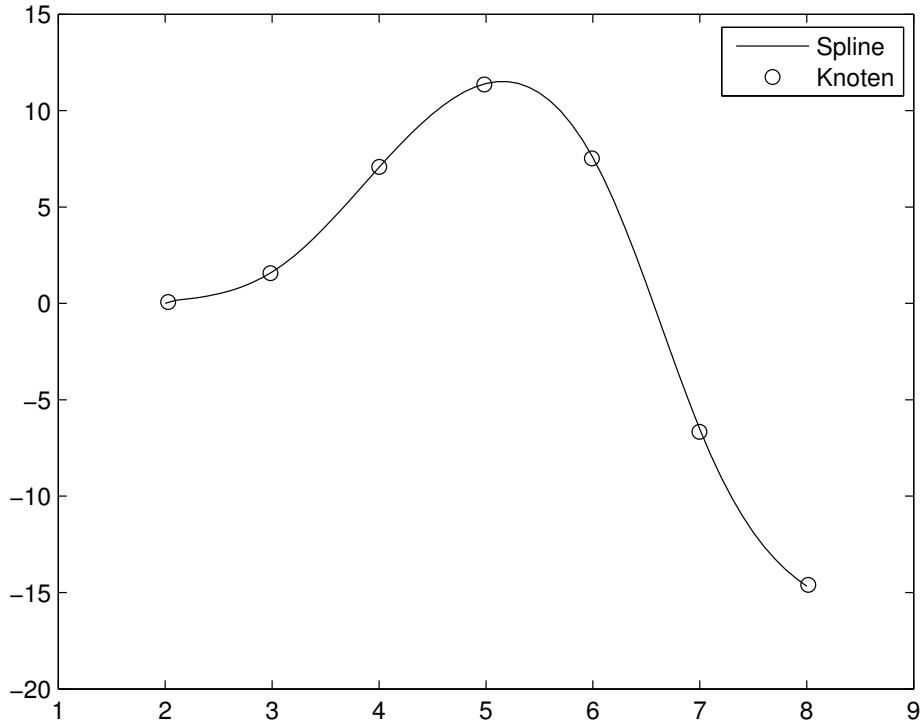


Abbildung 3.5: Ein uniformer kubischer Spline.

### 3.4.1 Herleitung einer Matrix-Darstellung

Gesucht wird die Basis der kubischen Splines  $N_r^3(t)$ ,  $r = [1 \dots 4]$ . Die vier kubischen Basis-Splines haben die allgemeine Form

$$N_r^3(t) = a_r t^3 + b_r t^2 + c_r t + d_r \quad \text{für } r = [1 \dots 4]. \quad (3.9)$$

Da im Folgenden nur noch kubische Splines betrachtet werden wird die Schreibweise der Basisfunktionen vereinfacht:

$$N_r(t) := N_r^3(t). \quad (3.10)$$

Die 16 Koeffizienten werden im Folgenden für einen uniformen B-Spline bestimmt.

Definiert wird ein uniformer Knotenvektor

$$\mathbf{T} = [t_0, \dots, t_m], \quad t_{j+1} - t_j = 1, \quad j \in [0 \dots m-1]. \quad (3.11)$$

Damit wird im konkreten Fall eines uniformen kubischen Splines ein Spline-Segment  $i$  zu (vgl. Gl. 3.5)

$$S_i(t) = \sum_{r=1}^4 N_r(t) c_{i+r-1}, \quad t \in [0, 1]. \quad (3.12)$$

Betrachtet werden zunächst Spline-Segmente im Inneren des Splines. Eine Betrachtung der Ränder und die Festlegung von Randbedingungen folgt im Anschluss.

Für einen uniformen kubischen Spline mit dem definierten Knotenvektor  $\mathbf{T}$  aus Gleichung 3.11 gilt nach Gleichung 3.2 bis 3.4

$$S_i^{(a)}(1) = S_{i+1}^{(a)}(0), \quad a = [0, 1, 2]. \quad (3.13)$$

Einsetzen von Gleichung 3.12 in 3.13 ergibt

$$\sum_{r=1}^4 N_r^{(a)}(1) c_{i+r-1} = \sum_{r=1}^4 N_r^{(a)}(0) c_{i+1+r-1}, \quad a = [0, 1, 2]. \quad (3.14)$$

Durch Koeffizientenvergleich aller fünf Kontrollpunkte  $[c_i, c_{i+1}, c_{i+2}, c_{i+3}, c_{i+4}]$  für alle  $a = [0, 1, 2]$  erhält man die 15 Gleichungen:

$$N_1^{(a)}(1) = 0 \quad \text{für } c_i \quad (3.15)$$

$$N_r^{(a)}(1) = N_{r-1}^{(a)}(0) \quad \text{für } c_{i+r}, \quad r = [1, 2, 3] \quad (3.16)$$

$$0 = N_4^{(a)}(0) \quad \text{für } c_{i+4}. \quad (3.17)$$

Um die 16 unbekannten Koeffizienten zu bestimmen fehlt eine weitere Gleichung. Diese erhält man sinnvollerweise durch die Normierung der Basis-Splines zu Eins. Das bedeutet, dass die Summe aus allen Basis-Splines zu einem beliebigen Parameter  $\hat{t}$  gleich eins ist:

$$\sum_{r=1}^4 N_r(\hat{t}) = 1, \quad \hat{t} \in [0, 1]. \quad (3.18)$$

Setzt man nun das allgemeine kubische Polynom (vgl. Gl. 3.9) in die Gleichungen 3.15 bis 3.18 ein, erhält man ein lineares Gleichungssystem aus 16 Gleichungen mit 16 Unbekannten ( $a_r, b_r, c_r, d_r, \quad r = [1, 2, 3, 4]$ ). In [Bar83] wird dieses Gleichungssystem explizit gelöst. Man erhält die vier kubischen Basis-Splines:

$$N_1(t) = \frac{1}{6}(-t^3 + 3t^2 - 3t + 1) \quad (3.19)$$

$$N_2(t) = \frac{1}{6}(3t^3 - 6t^2 + 4) \quad (3.20)$$

$$N_3(t) = \frac{1}{6}(-3t^3 + 3t^2 + 3t + 1) \quad (3.21)$$

$$N_4(t) = \frac{1}{6}t^3. \quad (3.22)$$

Durch Umformen in Matrixschreibweise ergibt sich

$$\mathbf{N}(t) = \frac{1}{6} \begin{bmatrix} t^3 & t^2 & t & 1 \end{bmatrix} \begin{bmatrix} -1 & 3 & -3 & 1 \\ 3 & -6 & 3 & 0 \\ -3 & 0 & 3 & 0 \\ 1 & 4 & 1 & 0 \end{bmatrix}. \quad (3.23)$$

Abbildung 3.6 zeigt die vier kubischen Basis-Splines.

Da die Basis der uniformen kubischen B-Splines nun bekannt ist, erhält man mit Gleichung 3.12 eine einfache Matrixrepräsentation für ein kubisches Spline-Segment  $i$  mit seinen Kontrollpunkten  $[c_i, c_{i+1}, c_{i+2}, c_{i+3}]^\top$ :

$$S_i(t) = \frac{1}{6} \begin{bmatrix} t^3 & t^2 & t & 1 \end{bmatrix} \begin{bmatrix} -1 & 3 & -3 & 1 \\ 3 & -6 & 3 & 0 \\ -3 & 0 & 3 & 0 \\ 1 & 4 & 1 & 0 \end{bmatrix} \begin{bmatrix} c_i \\ c_{i+1} \\ c_{i+2} \\ c_{i+3} \end{bmatrix}, \quad \text{für } t \in [0, 1]. \quad (3.24)$$

Die Gleichung 3.24 gilt so noch nicht für die beiden Spline-Segmente am Rand der B-Spline Kurve  $S_1(t)$  und  $S_{n-3}(t)$ , da hier die Bedingungen der Gleichheit und Differenzierbarkeit aus Gleichung 3.5 nicht erfüllt sind. Es müssen Randbedingungen festgelegt werden, um die Kontrollpunkte  $c_1$  und  $c_n$  zu bestimmen und somit die B-Spline Kurve an ihren Rändern wohl zu definieren. Die Betrachtung der Ränder folgt in Abschnitt 3.4.2.

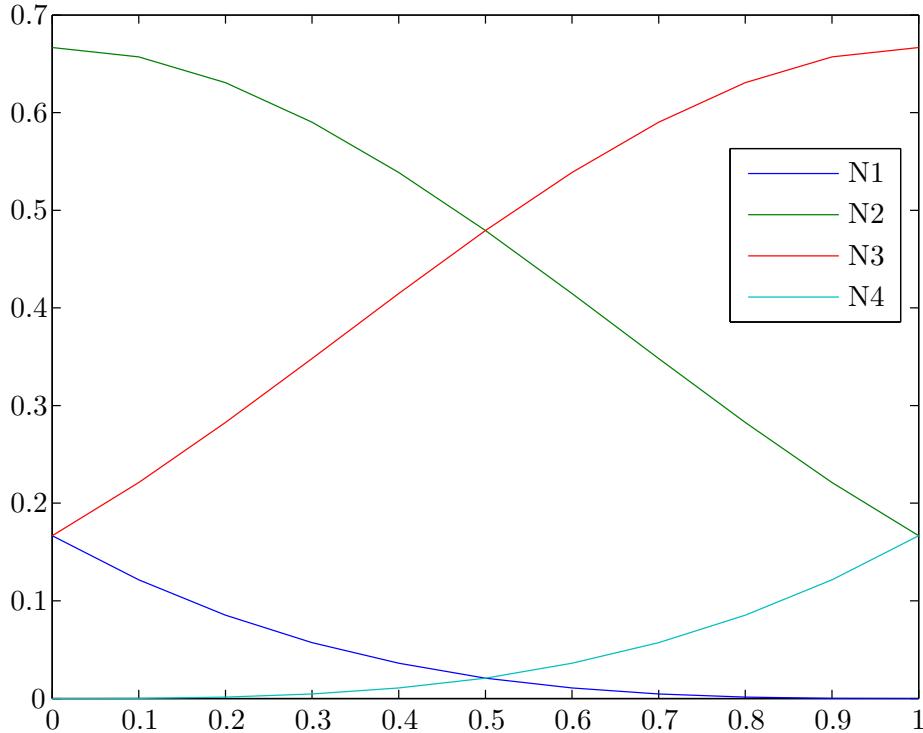


Abbildung 3.6: Die vier kubischen Basis-Splines.

Mit Beachtung der Randbedingungen erhält man dann eine geschlossene Form einer uniformen kubischen B-Spline mit dem Knotenvektor  $\mathbf{T}$  aus Gleichung 3.11:

$$S(t) = \sum_{i=1}^{n-3} S_i(t - t_i). \quad (3.25)$$

Aus  $n \geq 4$  Kontrollpunkten  $[c_1 \dots c_n]^\top$  lässt sich so ein Spline mit  $n-3$  Spline-Segmenten konstruieren.

### 3.4.2 Randbedingungen

Damit Gleichung 3.24 auch an den Rändern gilt müssen die Kontrollpunkte  $c_1$  und  $c_n$  über Randbedingungen festgelegt werden. Sinnvolle Randbedingungen sind die Interpolation eines Punktes oder die Vorgabe der ersten bzw. zweiten Ableitung an den Rändern.

In dieser Arbeit soll der Spline an den Rändern durch bestimmte Punkte laufen. Daher wird diese Randbedingung im Folgenden explizit dargestellt. Eine detaillierte Übersicht aller möglichen Randbedingungen sowie ihre Ausführung findet sich in [Bar83].

Es soll gelten:

$$S_1(0) \stackrel{!}{=} P_0 \quad (3.26)$$

$$S_{n-3}(1) \stackrel{!}{=} P_1 \quad (3.27)$$

Mit Gleichung 3.24 erhält man:

$$S_1(0) = \frac{1}{6}(c_1 + 4c_2 + c_3) = P_0 \quad (3.28)$$

$$S_{n-3}(1) = \frac{1}{6}(c_{n-2} + 4c_{n-1} + c_n) = P_1 \quad (3.29)$$

Somit ergeben sich die Bedingungen für die Kontrollpunkte  $c_1$  und  $c_n$ :

$$c_1 = 6P_0 - (4c_2 + c_3) \quad (3.30)$$

$$c_n = 6P_1 - (4c_{n-1} + c_{n-2}). \quad (3.31)$$

## 3.5 Mathematische Schätzverfahren

### 3.5.1 Methode der kleinsten Fehlerquadrate

Mit Hilfe der Methode der kleinsten (Fehler-)Quadrate (engl.: *Least Squares*) lassen sich die Parameter eines Modells aus einem überbestimmten Gleichungssystem schätzen. Ist das zu schätzende Modell linear in seinen Parametern und sind die auftretenden Fehler zufällig, d.h. unkorreliert, von gleicher Varianz und haben den Erwartungswert Null, dann ist dieser Schätzer optimal (Satz von Gauß-Markow).

Der Least-Squares-Schätzer findet häufig Anwendung in der Ausgleichsrechnung bei der eine Funktion (Modell) bestmöglich in vorhandene Datenpunkte (bzw. Messungen) gelegt wird. Dabei muss die grundlegende Struktur des Modells vorab bekannt sein.

Gegeben ist eine Messreihe  $(x_i, y_i), i = 1 \dots n$  sowie ein allgemeines Modell  $y = f(x, \boldsymbol{\alpha})$  mit  $m$  linearen Modellparametern  $\boldsymbol{\alpha} = \alpha_1 \dots \alpha_m$ . Ziel ist es die Parameter  $\boldsymbol{\alpha}$  des Modells so anzupassen, dass der Fehler aller Messpunkte zur geschätzten Kurve minimal wird.

Der Fehler bzw. das Residuum  $e_i$  eines Messpunktes  $i$  zur Schätzung beträgt:

$$e_i = y_i - f(x_i, \boldsymbol{\alpha}). \quad (3.32)$$

Die Summe  $S$  der Quadrate aller Fehler soll möglichst klein werden, um das Modell bestmöglich in die Messpunkte zu legen:

$$S(\boldsymbol{\alpha}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{\alpha}))^2 \quad (3.33)$$

$$\hat{\boldsymbol{\alpha}} = \min_{\boldsymbol{\alpha}} S(\boldsymbol{\alpha}) \quad (3.34)$$

Das entstandene Minimierungsproblem wird gelöst indem die partiellen Ableitungen der  $m$  Modellparameter zu Null gesetzt werden:

$$\frac{\partial S}{\partial \alpha_j} = 2 \sum_{i=1}^n e_i \frac{\partial e_i}{\partial \alpha_j} = 0, \quad j = 1, \dots, m. \quad (3.35)$$

Schreibt man Gleichung 3.32 in Matrixform für alle Messungen  $i$  erhält man:

$$\mathbf{e} = \mathbf{y} - \mathbf{H}\boldsymbol{\alpha}. \quad (3.36)$$

Die Summe aller Fehlerquadrate ergibt sich somit zu:

$$E = \mathbf{e}^\top \mathbf{e} = (\mathbf{y} - \mathbf{H}\boldsymbol{\alpha})^\top (\mathbf{y} - \mathbf{H}\boldsymbol{\alpha}). \quad (3.37)$$

Durch Minimierung des Gütekriteriums  $E$

$$\frac{\partial E}{\partial \boldsymbol{\alpha}} = 0 \quad (3.38)$$

erhält man die Parameter  $\hat{\boldsymbol{\alpha}}$  für die die Summe aller Fehler minimal wird. Durch Ausmultiplizieren, Ableiten und Umformen von Gleichung 3.37 erhält man die gängige Gleichung des Least Squares Schätzers:

$$(\mathbf{H}^\top \mathbf{H})\hat{\boldsymbol{\alpha}} = \mathbf{H}^\top \mathbf{y}. \quad (3.39)$$

### 3.5.2 Weighted Least Squares

Der im vorangegangenen Abschnitt vorgestellte *Least Squares Schätzer* impliziert, dass alle Messungen die gleiche Varianz haben und von gleicher Wichtigkeit sind. Ist dies nicht der Fall kann jeder Messung  $i$  ein Gewicht  $w_i$  zugeordnet werden. Gleichung 3.33 erweitert sich dann zu:

$$S(\boldsymbol{\alpha}) := \sum_{i=1}^n w_i(y_i - f(x_i, \boldsymbol{\alpha}))^2. \quad (3.40)$$

Nach [Ait35] wird dieser Schätzer optimal wenn das Gewicht  $w_i$  gleich dem reziproken der Varianz dieser Messung entspricht:

$$w_i = \frac{1}{\sigma_i^2}. \quad (3.41)$$

Da in der Praxis die Varianz einer Messung oft nicht bekannt ist können auch andere Größen für die Gewichtung gewählt werden. Ein Beispiel ist die Vertrauenswürdigkeit einer Messung, insofern diese während der Messung ermittelt werden kann.

### 3.5.3 M-Estimator

Der *M-Estimator* ist ein iteratives Verfahren auf Basis des *Weighted Least Squares Schätzers*. Die Gewichte  $w_i$  einer Messung werden dabei in jedem Iterationsschritt entsprechend ihrer Modellzugehörigkeit angepasst.

In der ersten Iteration werden die Modellparameter mit Hilfe des gewöhnlichen *Least Squares Schätzers* geschätzt. Im Anschluss wird jeder Messung entsprechend ihres Fehlers  $e$  zum Modell ein Gewicht zugeordnet. Diese Gewichtung erfolgt über eine Gewichtungsfunktion  $w(e)$  die die Gewichte der Messungen die das Modell gut repräsentieren erhöht und die Gewichte der Messungen mit großem Fehler verkleinert. Bild 3.7 zeigt eine Auswahl möglicher Gewichtungsfunktionen  $w(e)$ .

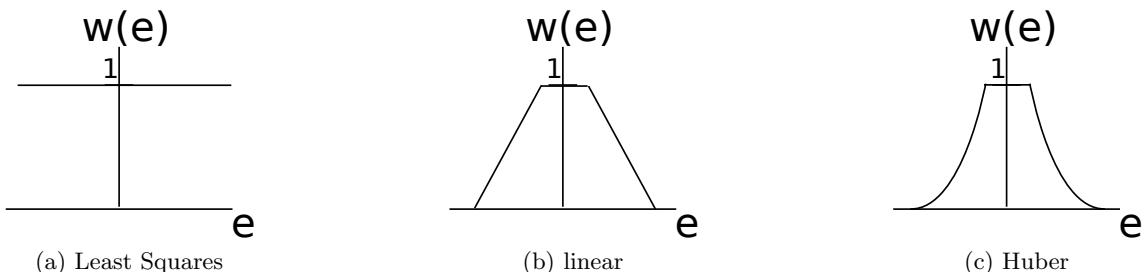


Abbildung 3.7: Gewichtungsfunktionen  $w(e)$ .

Das Gewicht  $w_i$  einer Messung ist somit abhängig von den (geschätzten) Modellparametern selbst. Daraus ergibt sich aus der Gleichung 3.40 des *Weighted Least Squares* zusammen mit dem Minimierungsansatz aus Gleichung 3.34 die Lösung für einen Iterationsschritt im *M-Estimator*:

$$\boldsymbol{\alpha}_{t+1} = \min_{\boldsymbol{\alpha}} \sum_{i=1}^n w_i(\boldsymbol{\alpha}_t)(y_i - f(x_i, \boldsymbol{\alpha}))^2. \quad (3.42)$$

Im nächsten Iterationsschritt haben Messungen mit großem Fehler entsprechend der Gewichtungsfunktion  $w(e)$  ein geringeres Gewicht und beeinflussen die Schätzung der Modellparameter weniger. Unter der Voraussetzung einer guten Startschätzung nähert das Verfahren somit in einem iterativen Prozess die Modellparameter den Messungen mit der besten Modellrepräsentation an. Gleichzeitig verschwindet der Einfluss von Ausreißern in den Messungen.

Abbildung 3.8 zeigt exemplarisch zwei Iterationen des *M-Estimators* für die Schätzung einer Geraden (grau). Die Größe der Messpunkte (schwarz) entspricht dem Gewicht dieser Messung für die nächste Schätzung. Es ist zu erkennen, dass der Einfluss der Ausreißer abnimmt während die Gewichtung der übrigen Punkte zunimmt.

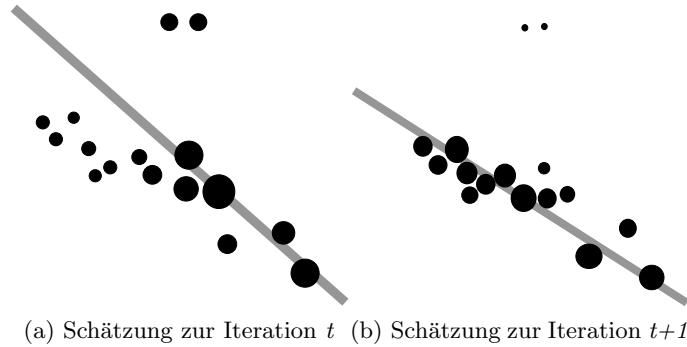


Abbildung 3.8: Zwei Iterationen im *M-Estimator*.

### 3.5.4 Kalman Filter

Das Kalman Filter ist ein Zustandsschätzer unter der Bedingung eines (bis auf seine Parameter) bekannten linearen dynamischen Modells. Während viele Schätzverfahren lediglich die aktuelle Messung verwenden, um den Zustand des Systems zu schätzen, berücksichtigt das Kalman Filter die vorangegangenen Zustände sowie den durch das bekannte dynamische Modell des Systems zu erwartenden Zustand. Dadurch lässt sich eine höhere Genauigkeit des geschätzten Systemzustands erzielen. Durch die Beachtung der vorangegangenen Zustände glättet das Kalman Filter zudem die Zustandsvektoren zeitlich und filtert so Ausreißer in den Messungen robust heraus.

Das Kalman Filter ist ein rekursiver Schätzer. Das bedeutet, zur Schätzung des aktuellen Zustands verwendet es lediglich den vorherigen Zustand sowie die aktuelle Messung. Dies impliziert, dass alle Informationen aus allen vorangegangenen Messungen bereits in die vorangegangene Schätzung eingeflossen sind und somit nicht weiter berücksichtigt werden müssen.

Die Anwendung des Kalman Filters folgt stets einem formalen Algorithmus und wird im Folgenden beschrieben. Eine ausführliche Arbeit über die Theorie und eine Herleitung des Kalman Filters findet man in [Rib04]. Eine übersichtliche Einführung des Kalman Filters bietet auch [WB95].

Gegeben ist ein lineares Modell mit der Zustandsgleichung

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \mathbf{w}_k, \quad (3.43)$$

mit dem Zustandsvektor  $\mathbf{x}$ , der Systemmatrix  $\mathbf{A}$ , dem Eingangsvektor  $\mathbf{u}$ , der Eingangsmatrix  $\mathbf{B}$  und einem unkorrelierten normalverteilten Prozessrauschen  $\mathbf{w}$  mit Kovarianz  $\mathbf{Q}$ . Weiterhin ist die Messgleichung bekannt:

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k, \quad (3.44)$$

mit den Messungen  $\mathbf{z}$ , der Beobachtungsmatrix  $\mathbf{H}$  und dem normalverteilten Messrauschen  $\mathbf{v}$  mit Kovarianz  $\mathbf{R}$ .

Die Ausgabe des Kalman Filters ist eine Schätzung des Systemzustands  $\hat{\mathbf{x}}$  sowie eine Zustands-Kovarianzmatrix  $\mathbf{P}$  die die Genauigkeit des geschätzten Systemzustands angibt. Das Kalman Filter lässt sich in zwei Schritte aufteilen, einen Prädiktionsschritt und einen Korrekturschritt. Zur Unterscheidung des Systemzustands zwischen beiden Schritten wird

der Zustandsvektor der Prädiktion mit  $\hat{\mathbf{x}}^-$  und der Zustandsvektor nach der Korrektur mit  $\hat{\mathbf{x}}^+$  symbolisiert. Analoges gilt für die Zustands-Kovarianzmatrix  $\mathbf{P}$ .

Bei der Prädiktion wird mit Hilfe des vorangegangene Zustands und der Zustandsgleichung 3.43 der aktuelle Zustand prädiziert:

$$\hat{\mathbf{x}}_k^- = \mathbf{A}_k \hat{\mathbf{x}}_{k-1} + \mathbf{B}_k \mathbf{u}_{k-1}. \quad (3.45)$$

Mit Hilfe des linearen Modells wird auch die Kovarianzmatrix prädiziert und ergibt somit ein Maß für die Genauigkeit der gemachten Prädiktion:

$$\mathbf{P}_k^- = \mathbf{A}_k \mathbf{P}_{k-1} \mathbf{A}_k^\top + \mathbf{Q}_k. \quad (3.46)$$

Im zweiten Schritt des Kalman Filters, dem Korrekturschritt, wird die Prädiktion mit den aktuellen Messungen fusioniert und daraus eine korrigierte Zustandsschätzung  $\hat{\mathbf{x}}_k^+$  berechnet. Dazu wird zunächst der Fehler, auch Innovation genannt, zwischen der aktuellen Messung  $\mathbf{z}_k$  und dem prädizierten Zustand bestimmt:

$$\mathbf{y}_k = \mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_k^-. \quad (3.47)$$

Die Innovation ist ein Maß für die Güte des prädizierten Modells um die gemachten Beobachtungen zu repräsentieren. Neben der Vertrauenswürdigkeit des prädizierten Modells ist es ebenso von Bedeutung die Unsicherheit der Messungen zu beachten.

Zur Korrektur des prädizierten Zustands mit der aktuellen Messung wird ein Proportionalitätsfaktor gesucht der unter Berücksichtigung der Varianz der Prädiktion  $\mathbf{P}_k^-$  und der Varianz der Messung  $\mathbf{R}_k$  den Systemzustand so korrigiert, dass die Varianz der Korrektur  $\mathbf{P}_k^+$  minimal wird. Diese Bedingung erfüllt die *Kalman-Matrix*  $\mathbf{K}$ :

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{H}_k^\top (\mathbf{H}_k \mathbf{P}_k^- \mathbf{H}_k^\top + \mathbf{R}_k)^{-1}. \quad (3.48)$$

Die korrigierte Zustandsschätzung ergibt sich mit Hilfe der *Kalman-Matrix* als Linearkombination aus Prädiktion und Innovation:

$$\hat{\mathbf{x}}_k^+ = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_k^-) \quad (3.49)$$

$$\mathbf{P}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_k^-. \quad (3.50)$$

Der korrigierte Zustand  $\hat{\mathbf{x}}_k^+$  liegt nun im besten Verhältnis von Prädiktion und Messung und geht in der nächsten Iteration als Zustandsvektor  $\hat{\mathbf{x}}_{k-1}$  in das Kalman Filter ein.

### 3.5.5 Informationsfilter

Das Informationsfilter ersetzt den prädizierten Zustandsvektor  $\hat{\mathbf{x}}_k^-$  des Kalman Filters durch den Informations-Zustandsvektor  $\hat{\mathbf{y}}_k^-$  und die Kovarianzmatrix durch die Informationsmatrix  $\mathbf{Y}_k^-$ . Diese sind wie folgt definiert:

$$\hat{\mathbf{y}}_k^- := (\mathbf{P}_k^-)^{-1} \hat{\mathbf{x}}_k^- \quad (3.51)$$

$$\mathbf{Y}_k^- := (\mathbf{P}_k^-)^{-1}. \quad (3.52)$$

Aus den Gleichungen für die Prädiktion und die Korrektur des Kalman Filters lassen sich entsprechende Gleichungen für das Informationsfilter ableiten. Die erhaltenen Gleichungen sind mathematisch identisch zu denen des Kalman Filters. Eine Herleitung der Gleichungen des Informationsfilters sowie ein Beweis der mathematischen Gleichheit findet man in [DW00] und [Kha].

Für die Korrektur des Informationsfilters ergibt sich dann

$$\hat{\mathbf{y}}_k^+ = \hat{\mathbf{y}}_k^- + \mathbf{i}_k \quad (3.53)$$

$$\mathbf{Y}_k^+ = \mathbf{Y}_k^- + \mathbf{I}_k \quad (3.54)$$

mit:

$$\mathbf{i}_k = \mathbf{H}_k^\top \mathbf{R}_k^{-1} \mathbf{z}_k \quad (3.55)$$

$$\mathbf{I}_k = \mathbf{H}_k^\top \mathbf{R}_k^{-1} \mathbf{H}_k. \quad (3.56)$$

Der Hauptvorteil des Informationsfilters liegt in der einfacheren numerischen Berechnung des Korrekturschritts. Während man für die Korrektur nach der herkömmlichen Kalman Gleichung 3.49, genauer gesagt für die Berechnung der Kalman Matrix, eine Matrixinversion der Größenordnung der Beobachtungsmatrix durchführen muss, ist für die Korrektur mit Hilfe des Informationsfilters (vgl. Gl. 3.53) nur noch eine Matrixinversion der Größenordnung des Zustandsvektors zu berechnen. Im konkreten vorliegenden Fall des Fahrbahnenschätzers reduziert sich damit die benötigte Inversion von einer etwa 1000x1000 auf eine 8x8 Matrix.

Analog der hier dargestellten Gleichungen für den Korrekturschritt des Informationsfilters lassen sich auch Gleichungen für die Prädiktion des Informationsfilters aus den Kalman Gleichungen ableiten. Da in dieser Arbeit jedoch ein alternatives Verfahren gegenüber der herkömmlichen Kalman-Prädiktion verwendet wird (vgl. Abschnitt 4.2.7), sei hier nur auf die im oberen Abschnitt genannten Quellen für den Prädiktionsschritt des Informationsfilters verwiesen.

## 4. Umsetzung

### 4.1 Überblick

Die Modellierung der befahrbaren Fläche erfolgt in der V-Disparität. Um das Modell mit Hilfe von Schätzverfahren bestmöglich in die V-Disparität legen zu können ist es von entscheidender Bedeutung, dass möglichst viele Punkte, die nicht zur Fahrbahn gehören, zuvor heraus gefiltert werden. Dazu werden Filterverfahren sowohl auf dem Disparitätenbild als auch auf der V-Disparität angewandt.

Als Modell dient eine B-Spline-Kurve bestehend aus fünf kubischen B-Splines. Die B-Spline-Kurve  $S$  bildet dabei die Disparitäten  $d$  auf eine Bildspalte  $v$  ab:

$$S : d \rightarrow v. \quad (4.1)$$

Jeder B-Spline liegt in einem fest definierten Abschnitt der V-Disparität. Die zu bestimmenden Modellparameter bestimmen die Form des B-Splines innerhalb dieses Abschnitts. Durch die Kombination von einem M-Estimator mit einem Kalman Filter werden die Modellparameter innerhalb der V-Disparität geschätzt, und darauf aufbauend eine Höhenkarte erstellt. Diese beinhaltet für jedes Pixel die Höhe über dem Fahrbahnprofil in dieser Entfernung.

Die genannten Schritte sind in mehrere Module aufgeteilt und werden im nachfolgenden Abschnitt im Detail dargestellt. Abbildung 4.1 stellt außerdem einen Überblick über die Anordnung aller Module sowie deren Verknüpfung dar.

### 4.2 Module

#### 4.2.1 Rollwinkelkompenstation

Bei der Erstellung der V-Disparität werden alle Punkte der gleichen Disparitäten einer Bildzeile aufsummiert. Für den idealisierten Fall, dass die Fahrbahn eine relativ zum Fahrzeug horizontal ausgerichtete Fläche ist haben in einer Bildzeile alle Punkte der Fahrbahn die gleiche Entfernung und bilden sich somit in der V-Disparität alle auf dem gleichen Punkt ab. Auf diese Weise würde man eine scharfe Linie innerhalb der V-Disparität erhalten, die die Fahrbahn repräsentiert.

Sobald die Ebene nicht mehr horizontal ausgerichtet ist verwischt diese Linie und wird mit steigendem Rollwinkel zunehmend unschärfer. Abbildung 4.2 zeigt die V-Disparität für unterschiedliche Rollwinkel.

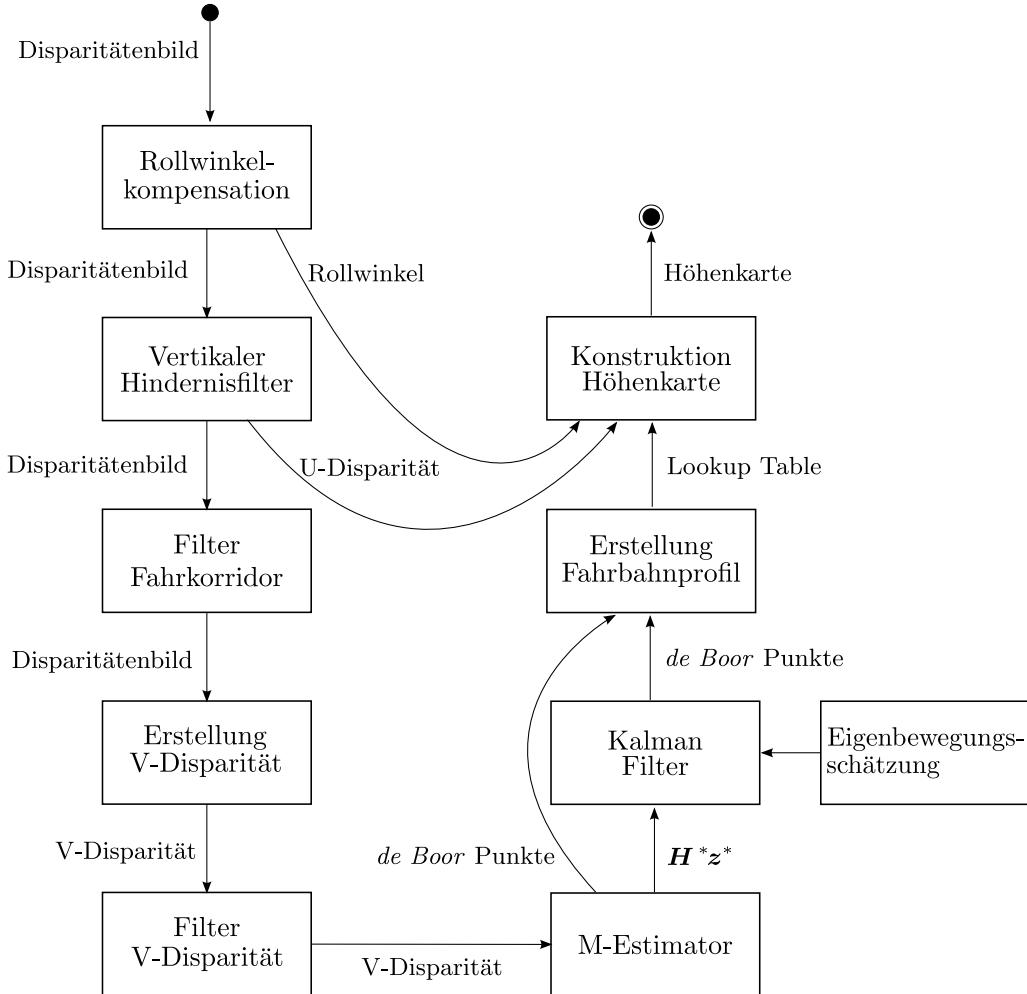


Abbildung 4.1: Anordnung der Module und ihre Schnittstellen.

Zur Bestimmung des Rollwinkels wird die Schärfe der V-Disparität herangezogen. Um eine Aussage über die Schärfe treffen zu können betrachtet man in einer Bildzeile das Verhältnis der maximalen Intensität zum Flächeninhalt unter der Intensitätsverteilung. Desto schärfer eine Bildzeile ist, desto größer wird dieser Quotient. Abbildung 4.3 zeigt für einen Drehwinkel  $\hat{\alpha}$  die V-Disparität und darin beispielhaft die Intensitätsverteilung entlang einer Bildzeile.

Um mit Hilfe des Schärfelektriums die gesamte V-Disparität bewerten zu können wird das Verhältnis für alle Bildzeilen bestimmt und das Ergebnis aufsummiert. Die daraus entstehende Summe wird als Gütemaß interpretiert, welche ein Maß für die Schärfe der V-Disparität für den Drehwinkel  $\alpha$  ist:

$$E(\alpha) = - \sum_v \frac{\max_d \{V(\alpha, d, v)\}}{\int_d V(\alpha, d, v) dd}. \quad (4.2)$$

Der Rollwinkel des Fahrzeugs ergibt sich nun aus demjenigen Drehwinkel  $\alpha$  für den die V-Disparität am schärfsten ist, das Gütemaß aus Gleichung 4.2 also minimal wird:

$$\Phi = \arg \min_{\alpha} \{E(\alpha)\}. \quad (4.3)$$

Für eine Inertialschätzung des Rollwinkels muss ein großer Wertebereich von Drehwinkeln  $\alpha$  ausgewertet werden. Für Folgeschätzungen kann dann stets der vorherige Rollwinkel benutzt werden, um den Suchraum einzuschränken. Außerdem eignet sich die Eigenbewegungsschätzung dazu den Bereich des neuen Rollwinkels zu prädizieren.

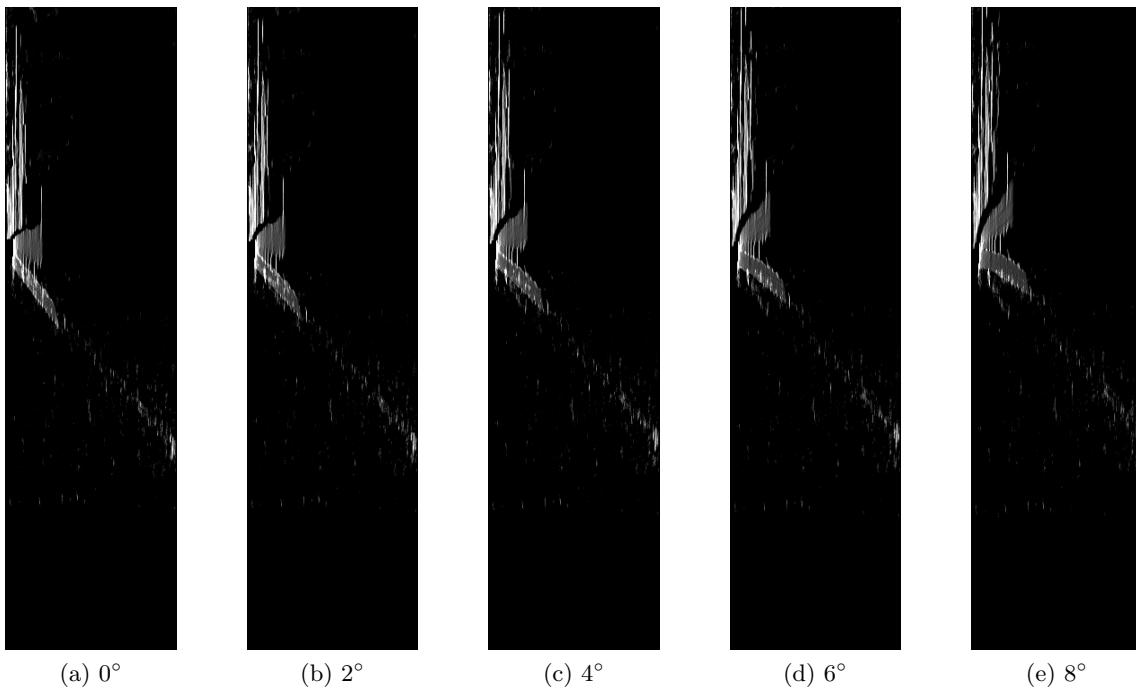


Abbildung 4.2: V-Disparität für unterschiedliche Rollwinkel.

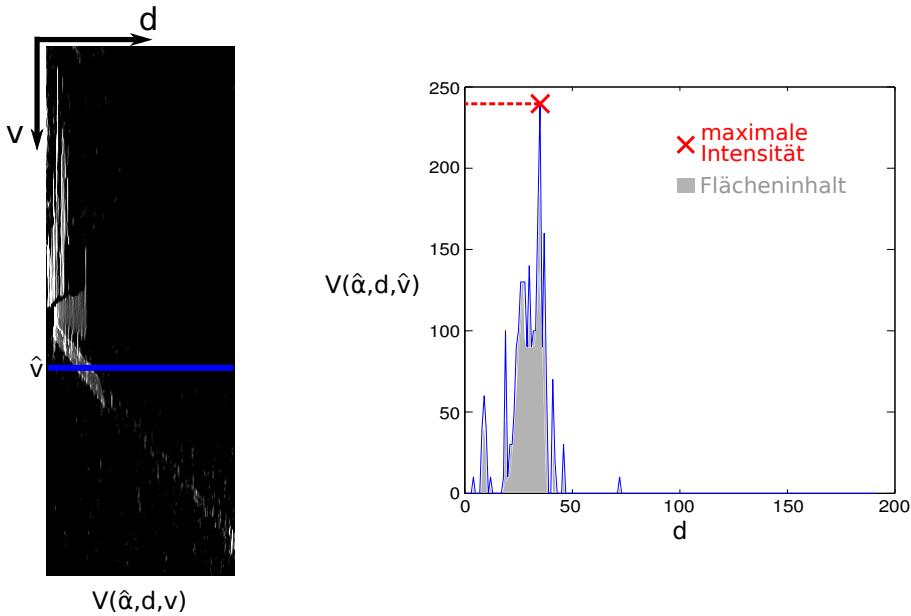


Abbildung 4.3: Intensitätsverteilung der V-Disparität.

#### 4.2.2 Beachtung des Fahrkorridors

Aus der momentanen Gierrate  $\dot{\Psi}$  des Fahrzeugs lässt sich der gefahrene Kurvenradius und damit der Straßenverlauf in direkter Nähe des Fahrzeugs bestimmen. Dieser Fahrkorridor wird dazu benutzt das Disparitätenbild zu filtern. Nur Punkte die innerhalb des Fahrkorridors liegen werden in die Schätzung der Fahrbahn einbezogen.

Die Eigenbewegungsschätzung liefert einen Gierwinkel  $\Delta\Psi$  den das Fahrzeug seit dem letzten Berechnungsschritt überstrichen hat sowie die Geschwindigkeit  $v$  des Fahrzeugs. Aus der Zeitspanne  $\Delta t$  ergibt sich die momentane Gierrate  $\dot{\Psi}$  des Fahrzeugs und daraus der

momentane Kurvenradius  $R$  zu:

$$R = \frac{v}{\dot{\Psi}}. \quad (4.4)$$

Die Begrenzungen des Fahrkorridors werden mit Hilfe der Kreisgleichung definiert. Die Breite des Fahrkorridors wird mit der Größe  $W$  bestimmt (vgl. Abb. 4.4).

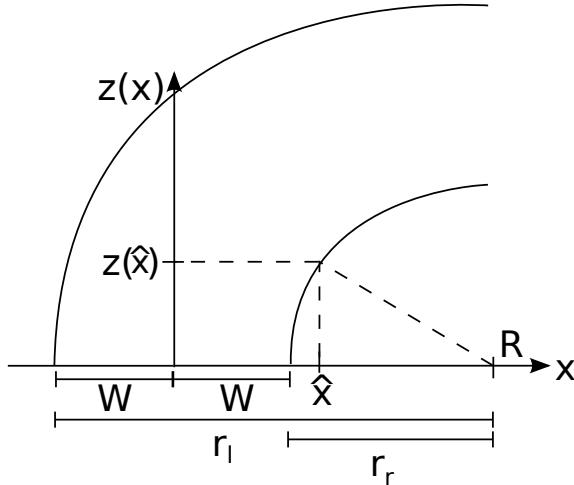


Abbildung 4.4: Bestimmung des Fahrkorridors.

Betrachtet man eine Rechtskurve lautet die Bedingung für den linken und rechten Rand:

$$z_{l/r}(x)^2 + (r_{l/r} - x)^2 = r_{l/r}^2, \quad \text{mit } r_{l/r} = R \mp W. \quad (4.5)$$

Mit Hilfe der Kreisgleichung erhält man für einen seitlichen Versatz  $\hat{x}$  zum Fahrzeug eine maximale bzw. minimale Entfernung  $z$  für den Fahrkorridor. Diese Bedingung lässt sich einfach mit Gleichung 3.1 in eine maximale bzw. minimale Disparität je Bildspalte  $d_{max/min}(u)$  umformulieren. Ein Pixel  $(u, v)$  wird dann in die Fahrbahnschätzung einbezogen wenn seine Disparität innerhalb der Grenzen des Fahrkorridors liegen:

$$d_{min}(u) \leq d(u, v) \leq d_{max}(u). \quad (4.6)$$

#### 4.2.3 Vertikaler Hindernisfilter

In der U-Disparität werden alle Disparitäten einer Bildspalte in einem Histogramm dargestellt. Hat ein Objekt über mehrere Bildzeilen hinweg die gleiche Entfernung, so bildet es sich in der U-Disparität als lokales Maximum ab (vgl. Abschnitt 3.1.2). Durch die Festlegung eines Grenzwertes  $T$  können so vertikalen Flächen detektiert und verworfen werden, da sie offensichtlich keine Punkte der Fahrbahn sind. Die Filervorschrift für das Disparitätsbild lautet somit:

$$d(u, v) \rightarrow \text{ungültig}, \quad \text{wenn } U(u, d(u, v)) > T. \quad (4.7)$$

Abbildung 4.5 zeigt das ursprüngliche Disparitätsbild sowie die dazugehörige U- und V-Disparität. Entsprechend der lokalen Maxima in der U-Disparität wird das Disparitätsbild nach Gleichung 4.7 gefiltert. Das reduzierte Disparitätsbild sowie die daraus entstehende V-Disparität sind in Abbildung 4.6 dargestellt. Es ist deutlich zu erkennen, dass die senkrechten Linien in der V-Disparität heraus gefiltert wurden.

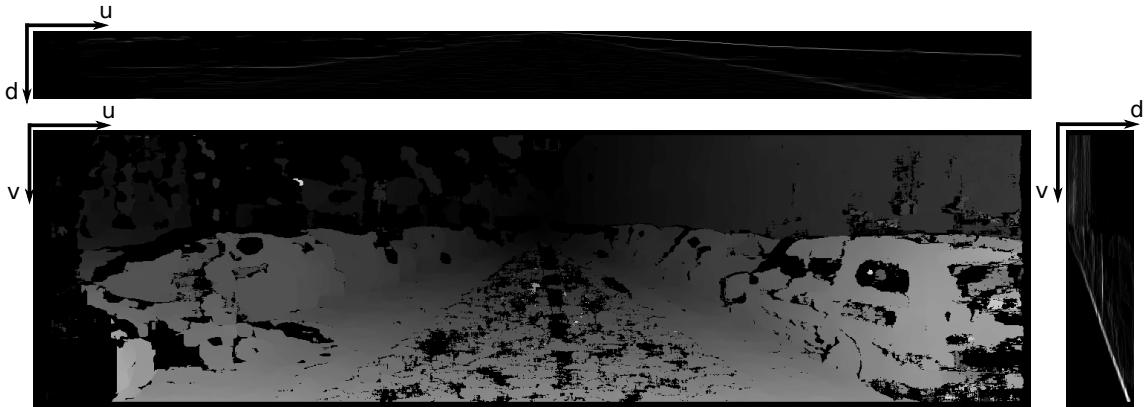


Abbildung 4.5: Original Disparitätenbild und Histogramme.



Abbildung 4.6: Disparitätenbild und V-Disparität nach Entfernung vertikaler Flächen.

#### 4.2.4 Gewichtung der V-Disparität

Wie man aus Abbildung 4.6 erkennen kann werden mit Hilfe der U-Disparität zwar einige Punkte die nicht zur Fahrbahn gehören entfernt, doch weiterhin sind viele Punkte vorhanden die die Schätzung verfälschen würden. Um den Einfluss dieser Punkte zu verringern werden auf die V-Disparität zwei Heuristiken angewandt, die Aussagen über die Lage der Fahrbahn in der V-Disparität treffen:

- (1) Für eine feste Entfernung bzw. Disparität  $\hat{d}$  entsprechen die Punkte am weitesten unten im Disparitätenbild Punkten auf der Fahrbahn.
- (2) Für eine feste Bildzeile  $\hat{v}$  im Disparitätenbild entsprechen die Punkte mit der größten Entfernung Punkten auf der Fahrbahn.

Die roten Pfeile in Abbildung 4.7a verdeutlichen die Bedeutung der beiden Heuristiken in der V-Disparität. Zusammengefasst gilt, dass die Fahrbahn den Punkten am weitesten links und unten in der V-Disparität entspricht.

Um die beiden Heuristiken anwenden zu können werden sie in einer mathematischen Beschreibung formuliert. Die erste Heuristik lässt sich ausdrücken indem man entlang einer Bildspalte das Verhältnis der überstrichenen Fläche zur Gesamtfläche betrachtet. Der Quotient ergibt eine Gewichtung für den Pixel im gefilterten Bild. Desto weiter man in einer Bildspalte nach unten kommt, desto größer wird das Gewicht:

$$W_{Av}(d, v) = \frac{\int_0^v V(d, v) dv}{\int_0^{v_{max}} V(d, v) dv}. \quad (4.8)$$

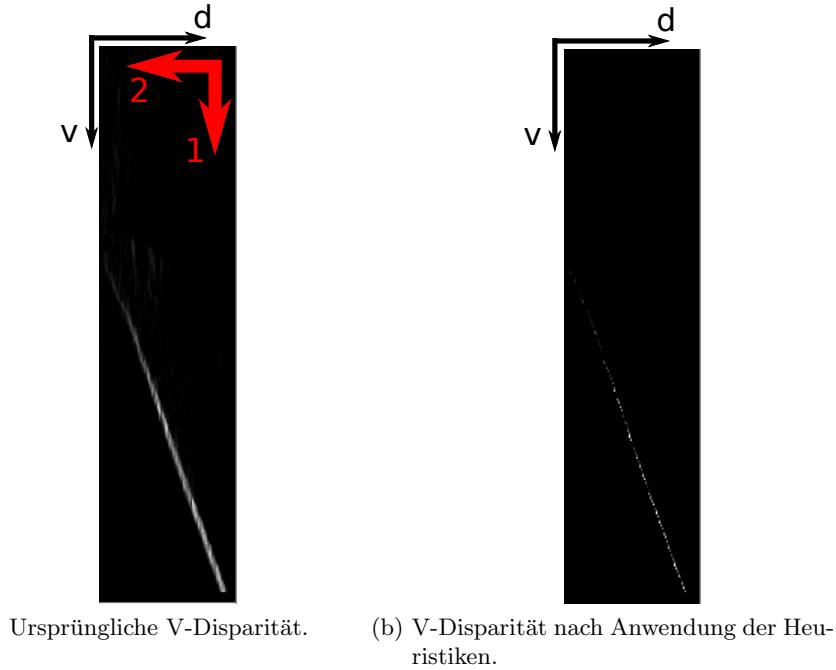


Abbildung 4.7: Anwendung der Heuristiken auf die V-Disparität.

Die zweite Heuristik lässt sich auf die gleiche Art beschreiben. Hier bildet man ausgehend vom rechten Rand der V-Disparität entlang einer Bildzeile das Verhältnis von überstrichener Fläche zur Gesamtfläche:

$$W_{A_d}(d, v) = \frac{\int_{d_{max}}^d V(d, v) dd}{\int_{d_{max}}^0 V(d, v) dd}. \quad (4.9)$$

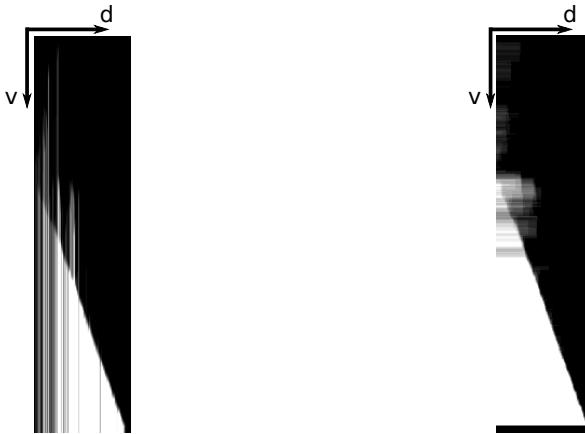
Besonders effizient lassen sich die Gewichte  $W_{A_v}$  und  $W_{A_d}$  mit Hilfe von Integralbildern berechnen. Integralbilder beinhalten in jedem Punkt die Summe aller Pixel zwischen einer Basis und dem aktuellen Punkt. Abbildung 4.8a zeigt das Integralbild  $I_v$  entlang der Bildspalten von oben nach unten, Abbildung 4.8b das Integralbild  $I_d$  von rechts nach links entlang der Bildzeilen.

Da die Integrale aus Gleichung 4.8 und 4.9 durch die Integralbilder ausgedrückt werden ergeben sich dann die Gewichte  $W_{A_v}$  und  $W_{A_d}$  aus der Division der entsprechenden Punkte zu:

$$W_{A_v}(d, v) = \frac{I_v(d, v)}{I_v(d, v_{max})} \quad (4.10)$$

$$W_{A_d}(d, v) = \frac{I_d(d, v)}{I_d(0, v)}. \quad (4.11)$$

Die Gewichte  $W_{A_v}(d, v)$  und  $W_{A_d}(d, v)$  sind in ihrer bisherigen Form sehr anfällig für Messfehler die in der V-Disparität unterhalb oder weiter links der tatsächlichen Fahrbahn liegen, da diese das maximale Gewicht erhalten. Um dies zu verhindern wird die Gewichtsverteilung  $W_{A_d}$  so transformiert, dass ihr Maximum nicht mehr bei 100%, sondern bei 95% der Gesamtfläche liegt. Abbildung 4.9 zeigt beispielhaft die Intensitätsverteilung der V-Disparität entlang zweier Bildzeilen sowie das daraus entstehende Gewicht  $W_{A_d}$  aus



(a) Integralbild entlang der Bildspalten. (b) Integralbild entlang der Bildzeilen von rechts nach links.

Abbildung 4.8: Integralbilder der V-Disparität.

Gleichung 4.9.

Da die Fahrbahn in der V-Disparität für eine feste Bildspalte bzw. Zeile einen deutlichen Häufungspunkt darstellt liegt das *95%-Kriterium* immer nahe dem tatsächlichen Maximum, während die Gesamtfläche beim Auftreten von Messfehlern erst bei sehr viel kleineren Bildspalten erreicht wird (vgl. Abb. 4.9b).

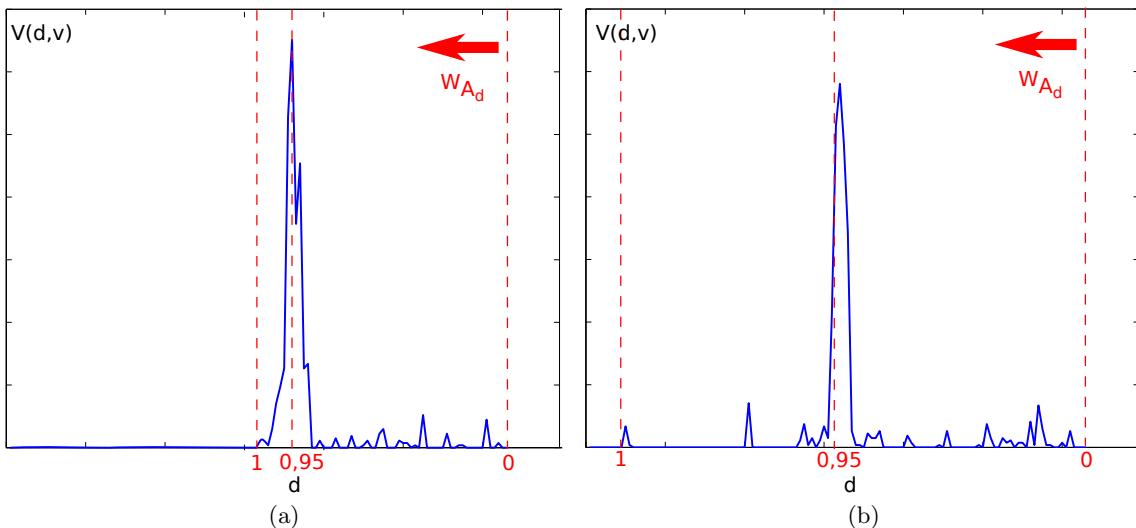


Abbildung 4.9: Gewichtsverteilung  $W_{A_d}$  ohne (links) und mit (rechts) Ausreißern.

Um das Gewicht  $W_A$  gemäß des *95%-Kriteriums* auf das neue Gewicht  $W$  zu transformieren wird bei Überschreitung von 95% des Flächeninhalts die Gewichtung linear gemäß Abbildung 4.10 zurückgenommen.

Anschließend wird dann jeder Punkt der V-Disparität mit seinem Gewicht multipliziert. Das Ergebnis dieses Filters ist in Abbildung 4.7b dargestellt.

#### 4.2.5 Übertragung der V-Disparität in die Messgleichung

Die zu schätzende B-Spline-Kurve wird aus fünf B-Splines zusammengesetzt. Da der B-Spline uniform ist sind alle Knotenpunkte äquidistant angeordnet. Die Abszisse der Knoten ist fest, lediglich die Ordinate verändert sich entsprechend der Messwerte. Abbildung 4.11

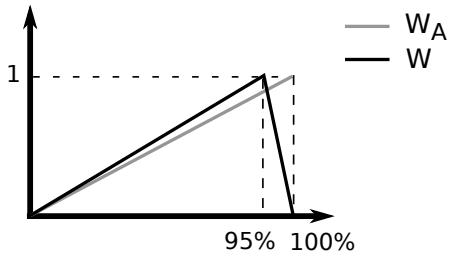


Abbildung 4.10: Transformation der Gewichtsverteilung.

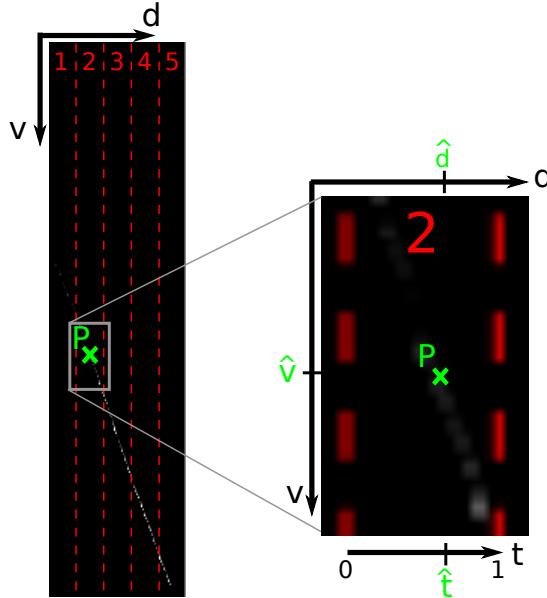


Abbildung 4.11: Eine Messung in der V-Disparität.

zeigt in rot die fünf Segmente des B-Splines.

Ein kubischer B-Spline wird durch vier *de Boor Punkte* eindeutig beschrieben. Jeder B-Spline teilt mit seinem Nachbarn drei *de Boor Punkte*. Daraus ergibt sich der zu schätzende Zustandsvektor mit acht *de Boor Punkten*:

$$\mathbf{x} = [c_1 \ c_2 \ c_3 \ c_4 \ c_5 \ c_6 \ c_7 \ c_8]^\top. \quad (4.12)$$

Um die Modellparameter schätzen zu können muss aus der gefilterten V-Disparität die Messgleichung

$$\mathbf{H}\mathbf{x} = \mathbf{z} \quad (4.13)$$

erstellt werden. Abbildung 4.11 zeigt die V-Disparität mit einer Beispieldmessung  $P$ .

Die Abszisse  $d$  einer Messung (bzw. eines Punktes)  $P(d, v)$  legt das zugehörige Spline-Stück fest. Zur Berechnung der vier Basiswerte dieses B-Splines muss zunächst die Disparität  $d$  auf den Kurvenparameter  $t \in [0 \dots 1]$  transformiert werden (vgl. Abb. 4.11). Der Parameter  $\hat{t}$  legt dann mit Hilfe der Basis der uniformen kubischen B-Splines die vier Basiswerte für diese Messung  $P$  fest (vgl. Abschnitt 3.4.1):

$$\mathbf{N}(t) = \frac{1}{6} \begin{bmatrix} t^3 & t^2 & t & 1 \end{bmatrix} \begin{bmatrix} -1 & 3 & -3 & 1 \\ 3 & -6 & 3 & 0 \\ -3 & 0 & 3 & 0 \\ 1 & 4 & 1 & 0 \end{bmatrix}. \quad (4.14)$$

Das zugehörige Spline-Segment der Messung legt fest welche *de Boor Punkte* die berechneten Basiswerte aus Gleichung 4.14 gewichten. Die Basiswerte des  $i$ -ten Spline-Stücks werden von den vier *de Boor Punkten*  $c_i \dots c_{i+4}$  gewichtet.

Der Messwert  $z$  der Messgleichung entspricht der Bildzeile  $v$  der Messung  $P(d, v)$ .

Um das Gewicht einer Messung zu beachten wird zusätzlich die gesamte Zeile der Messung in der Messgleichung mit dem Wert des Punktes  $V(d, v)$  multipliziert. Physikalisch betrachtet entspricht diese Multiplikation dem häufigeren Vorkommen dieser Messung. Anstatt die gleiche Messung jedoch mehrfach in die Messgleichung aufzunehmen, und damit die Beobachtungsmatrix  $H$  unnötig zu vergrößern, wird sie stattdessen mit ihrem Gewicht multipliziert, was im Zuge der Parameterschätzung mathematisch äquivalent ist.

Zusammengefasst ergibt sich die Messgleichung mit expliziter Darstellung der Beispielmessung aus Abbildung 4.11 zu:

$$\begin{bmatrix} 0 & N_1(\hat{t})V(\hat{d}, \hat{v}) & N_2(\hat{t})V(\hat{d}, \hat{v}) & N_3(\hat{t})V(\hat{d}, \hat{v}) & N_4(\hat{t})V(\hat{d}, \hat{v}) & 0 & 0 & 0 \\ \vdots & \vdots \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \\ c_5 \\ c_6 \\ c_7 \\ c_8 \end{bmatrix} = \begin{bmatrix} \vdots \\ \hat{v}V(\hat{d}, \hat{v}) \\ \vdots \end{bmatrix} \quad (4.15)$$

#### 4.2.6 Gewichtung der Messgleichungen

In einem iterativen Prozess schätzt der M-Estimator die Modellparameter und gewichtet die Messungen danach wie gut sie in der Lage sind das gemachte Modell zu repräsentieren (vgl. Abschnitt 3.5.3). Durch die iterative Anpassung der Gewichte entfernt er so den Einfluss von Ausreißern. Das Ergebnis des M-Estimators ist also neben den Modellparametern selbst ein Gütemaß für jede Messung, wie gut sie in der Lage ist das gemachte Modell zu repräsentieren.

Da das Kalman Filter im Anschluss (siehe nachfolgender Abschnitt) die Modellparameter nochmals, unter Einbeziehung der vorangegangenen Schätzung bestimmt, werden in der Regel die hier geschätzten Modellparameter verworfen. Das Gütemaß der Messungen wird hingegen benutzt, um die zuvor erstellte Beobachtungsmatrix  $H$  und die Messungen  $z$  zu gewichten. Sei  $w_i$  das Gütemaß für die Messung  $i$  aus dem M-Estimator, dann ergibt sich die neue Beobachtungsmatrix  $H^*$  und der neue Messvektor  $z^*$  zu:

$$H_{i,j}^* := H_{i,j} w_i \quad (4.16)$$

$$z_i^* := z_i w_i. \quad (4.17)$$

Abbildung 4.12 zeigt das Ergebnis des M-Estimators nach 15 Iterationen. Es ist deutlich zu erkennen, dass der Spline am linken Ende herunter gezogen wurde und so der Einfluss der Punkte, die zu weit oben liegen, reduziert wurde. Auch wenn die Modellparameter selbst verworfen werden, wird das erzielte Ergebnis implizit durch die Gewichtung der Messungen mit dem Gütemaß an das Kalman Filter weiter gegeben.

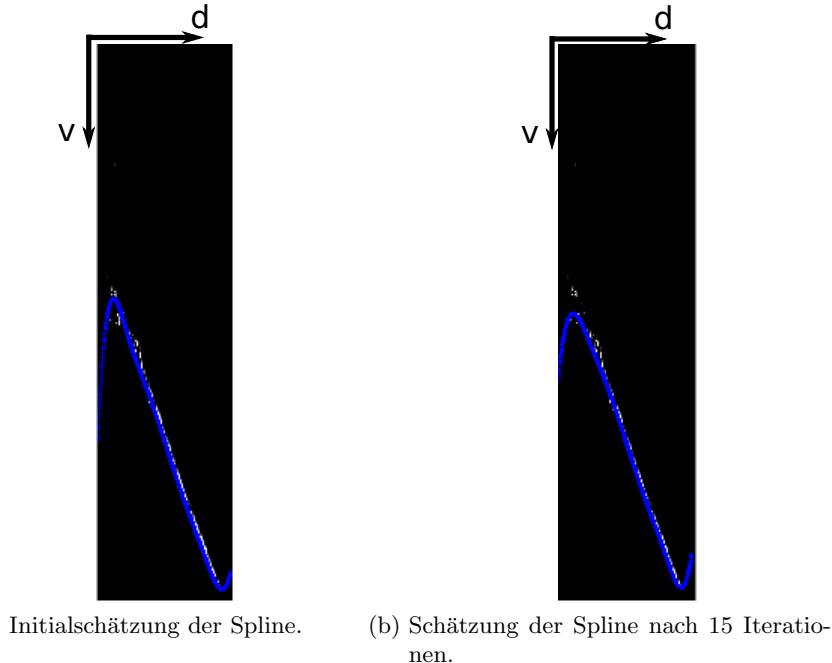


Abbildung 4.12: Iterative Schätzung der Spline mit dem M-Estimator.

#### 4.2.7 Kalman Filterung des Splines

Aus dem gewichteten Messvektor und der Beobachtungsmatrix aus dem M-Estimator werden mit Hilfe des Kalman Filters die Modellparameter geschätzt und zeitlich verfolgt.

Da die Systemmatrix  $\mathbf{A}$  für den Zustandsvektor in Bildkoordinaten nicht bekannt ist, muss ein alternativer Prädiktionsschritt für die Kalman-Filterung verwendet werden. Eine einfache Alternative, die häufig Anwendung findet, ist die Annahme eines konstanten Systemzustands. Der Zustandsvektor bleibt demnach bei der Prädiktion konstant, während die Kovarianz der Prädiktion um die Kovarianz  $\hat{\mathbf{Q}}_k$  des Prozessrauschens ergänzt wird:

$$\hat{\mathbf{x}}_k^- = \hat{\mathbf{x}}_{k-1}^+ \quad (4.18)$$

$$\hat{\mathbf{P}}_k^- = \hat{\mathbf{P}}_{k-1}^+ + \hat{\mathbf{Q}}_k. \quad (4.19)$$

Obwohl diese Art der Prädiktion formal korrekt ist, hat sie den Nachteil, dass das Modell aufgrund der konstanten Prädiktion relativ träge wird, und Änderungen der Fahrbahn im Kamerabild (z.B. durch Nicken des Fahrzeugs) erst zeitversetzt korrekt abgebildet werden. Aus diesem Grund wird in dieser Arbeit ein alternativer Prädiktionsschritt eingeführt, der die Prädiktion der Fahrbahn mit Hilfe der Eigenbewegungsschätzung in Fahrzeugkoordinaten durchführt. Aus der prädizierten Fahrbahn lässt sich dann ein prädizierter Zustandsvektor bestimmen. Abbildung 4.13 zeigt das Vorgehen schematisch.

Ausgehend von der Zustandsschätzung des vorherigen Zeitschritts werden, unter Verwendung der geschätzten *de Boor* Punkte, Punkte auf der Fahrzeugmittelebene berechnet (blau) und in Fahrzeugkoordinaten transformiert.

Die Eigenbewegungsschätzung liefert die vollzogene Translation sowie die Rotation des Fahrzeugs zwischen zwei Kamerabildern, ausgedrückt in der affinen Transformationsmatrix  $\mathbf{T}$  in homogenen Koordinaten. Mit Hilfe dieser Matrix wird die neue Lage des Fahrbahnpunktes prädiziert:

$$\mathbf{P}^* = \mathbf{T}\mathbf{P}. \quad (4.20)$$

Anschließend wird der prädizierte Fahrbahnpunkt wieder in Bildkoordinaten zurück transformiert (grün). Die Menge aller transformierten Punkte in der V-Disparität repräsentieren

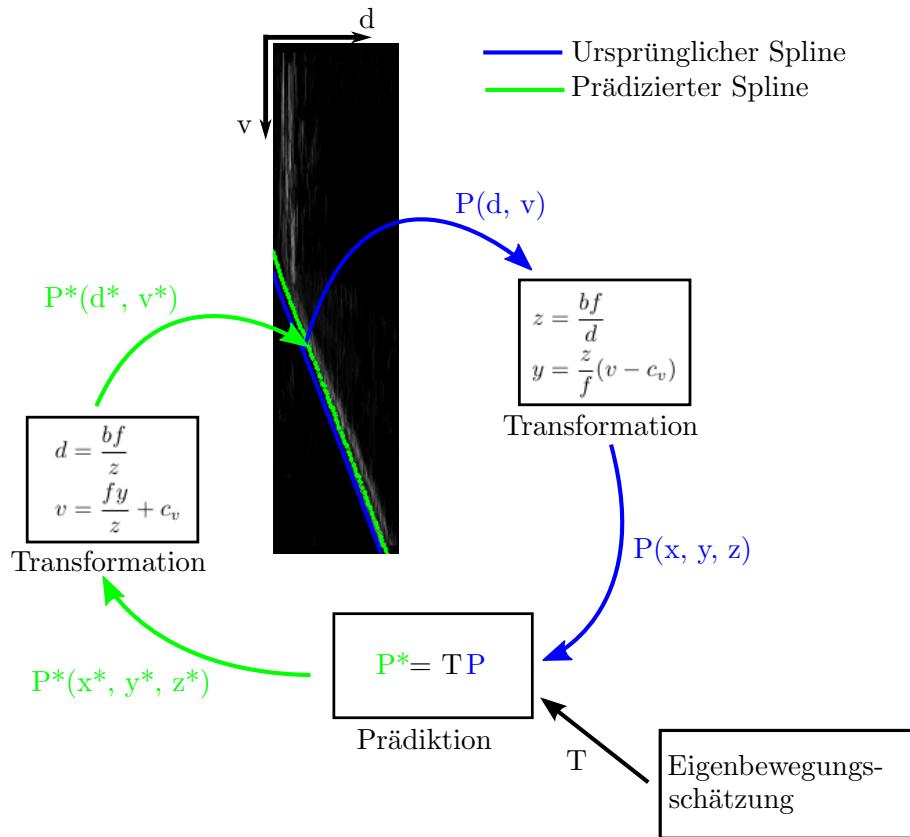


Abbildung 4.13: Prädiktionsschritt des Kalman Filters.

nun die prädizierte Lage der Fahrbahn in der V-Disparität unter der Annahme der aus der Eigenbewegungsschätzung stammenden Translation und Rotation des Fahrzeugs.

Der gesuchte Zustandsvektor für die Prädiktion  $\hat{x}_k^-$  kann jetzt mit Hilfe eines einfachen *Least-Squares* Schätzers auf Basis der prädizierten Fahrbahnpunkte gewonnen werden.

Zur Bestimmung der Kovarianz der Prädiktion  $\hat{P}_k^-$  wird die Kovarianz der alten Schätzung um die Kovarianz  $\hat{Q}_k$  des Prozessrauschens gemäß Gleichung 4.19 ergänzt.

Die hier beschriebene Prädiktion mit Hilfe der Eigenbewegungsschätzung beinhaltet einen großen Vorteil. Die Eigenbewegungsschätzung modelliert intern die gesamte Fahrzeugdynamik, ins Besondere den Nick- und Rollwinkel. Für einen korrekten Prädiktionsschritt, unter Beachtung der Fahrzeugdynamik, muss diese nicht in das Modell und damit in den Zustandsvektor integriert werden, sondern steckt implizit in den prädizierten Fahrbahnpunkten. Da diese wieder in Kamerakoordinaten transformiert werden, enthält der prädizierte Spline die gesamte Fahrzeugdynamik in Kamerakoordinaten, welche daher nicht weiter modelliert werden muss.

Der Korrekturschritt des Kalman Filters erfolgt mit Hilfe des Informationsfilters weitgehend nach dem formalen Verfahren (vgl. Abschnitt 3.5.5). Die Beobachtungsmatrix sowie der Messvektor entsprechen jedoch nicht den originalen Matrizen sondern enthalten die Gewichte aus dem M-Estimator. Die Korrekturgleichungen des Informationsfilters ergeben sich demnach zu:

$$\hat{y}_k^+ = \hat{y}_k^- + i_k \quad (4.21)$$

$$\mathbf{Y}_k^+ = \mathbf{Y}_k^- + \mathbf{I}_k \quad (4.22)$$

mit:

$$\mathbf{i}_k = \mathbf{H}_k^{*\top} \mathbf{R}_k^{-1} \mathbf{z}_k^* \quad (4.23)$$

$$\mathbf{I}_k = \mathbf{H}_k^{*\top} \mathbf{R}_k^{-1} \mathbf{H}_k^*. \quad (4.24)$$

Die Rücktransformation ergibt den gesuchten Zustandsvektor sowie die zugehörige Kovarianz:

$$\hat{\mathbf{P}}_k^+ = \mathbf{Y}_k^{+^{-1}} \quad (4.25)$$

$$\hat{\mathbf{x}}_k^+ = \hat{\mathbf{P}}_k^+ \hat{\mathbf{y}}_k. \quad (4.26)$$

#### 4.2.7.1 Gültigkeit der Zustandsschätzung durch das Kalman Filter

Im Prädiktionsschritt des Kalman Filters wird die Lage der Fahrbahn mit Hilfe der Eigenbewegungsschätzung in das neue Kamerakoordinatensystem prädiziert. Dieses Vorgehen ist solange gültig, solange man sich auf der gleichen Straße befindet. Wenn man allerdings, z.B. an einer Kreuzung, auf eine andere Straße abbiegt ist es nicht mehr sinnvoll den alten Straßenverlauf zu prädizieren. Aus diesem Grund wird die Zustandsschätzung durch das Kalman Filter beim Abbiegen ausgesetzt und stattdessen die Zustandsschätzung des M-Estimators als Grundlage für die nachfolgenden Schritte herangezogen. Sobald das Abbiegemanöver beendet ist wird das Kalman Filter zurückgesetzt und im Weiteren wieder als Zustandsschätzer verwendet.

Im Ausblick (vgl. Abschnitt 7.1) wird diese Problematik nochmals aufgegriffen und ein möglicher Ausweg aufgezeigt.

#### 4.2.8 Erstellung des Straßenprofils

Der geschätzte Zustandsvektor beschreibt einen Spline über dem gesamten Wertebereich der V-Disparität. Da gemäß des hyperbolischen Zusammenhangs zwischen Entfernung und Disparität (vgl. Gl. 3.1) auf kleine Disparitäten ein sehr großer Entfernungsreich abgebildet wird, muss das geschätzte Modell in diesem Bereich besonders präzise sein, um nicht schon bei kleinen Abweichungen große Fehler über den tatsächlichen Fahrbahnverlauf zu machen. Aus diesem Grund wird das Modell bzw. der Spline nachträglich einem Gütemaß unterzogen welches die maximal gültige Entfernung des Modells festlegt.

Als Maß dient hier die Anzahl und das Gewicht der Messpunkte die das Modell an einer bestimmten Disparität noch unterstützen. Um die Modellgrenze zu finden wird dazu ausgehend von der Mitte des Splines ein quadratisches Fenster entlang des Splines in Richtung kleiner Disparitäten verschoben. Das Modell ist solange gültig, bis entweder zu wenige Messpunkte innerhalb des Fensters liegen, und damit zu wenige Messpunkte den Spline stützen, oder die Messpunkte zusammen ein zu geringes Gewicht haben.

Neben der Bestimmung der Grenze des Modells wird außerdem die unhandliche Beschreibung des Fahrbahnprofils durch die *de Boor* Punkte durch zwei einfache Tabellen ersetzt. Die erste Tabelle enthält für jede diskrete Disparität des gesamten Wertebereichs der V-Disparität die Bildzeile  $v$  in der die Fahrbahn liegt. Die zweite Tabelle enthält die umgekehrte Zuordnung. Sie gibt für jede Bildzeile die Disparität der Fahrbahn an. Da die Fahrbahn im Kamerabild immer von oben nach unten, sowie von großen zu kleinen Entfernung verläuft, ist die Abbildung des Fahrbahnverlaufs in der V-Disparität stets monoton fallend. Aus diesem Grund sind die beiden genannten Zuordnungen immer eindeutig bestimmbar.

#### 4.2.9 Konstruktion der Höhenkarte

Nachdem das mathematische Modell des Fahrbahnprofils bekannt ist lässt sich aus dem Tiefenbild (bzw. dem äquivalenten Disparitätenbild) die Höhe jedes Bildpunktes relativ zum Straßenniveau bestimmen und daraus eine Höhenkarte konstruieren.

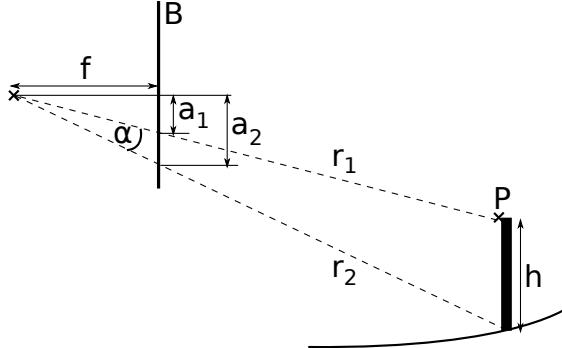


Abbildung 4.14: Konstruktion der Höhenkarte.

Ein beliebiger Punkt  $P$  bildet sich auf der Bildebene  $B$  im Abstand  $a_1$  zur Bildmitte ab (vgl. Abb. 4.14). Die dazugehörige Abbildung des Straßenniveaus im Abstand  $a_2$  ist aus dem Fahrbahnmodell bekannt.

Der Winkel  $\alpha$  der beiden Sichtstrahlen ergibt sich aus dem Schnittwinkel der beiden Geraden  $r_1$  und  $r_2$ :

$$\alpha = \arccos \left( \frac{\langle \mathbf{r}_1, \mathbf{r}_2 \rangle}{|\mathbf{r}_1| |\mathbf{r}_2|} \right) \quad (4.27)$$

mit den Richtungsvektoren

$$\mathbf{r}_1 = \begin{bmatrix} f \\ a_1 \end{bmatrix}, \quad \mathbf{r}_2 = \begin{bmatrix} f \\ a_2 \end{bmatrix}. \quad (4.28)$$

Die Entfernung  $|r_1|$  des Punktes  $P$  ergibt sich direkt aus der Disparität  $d$ , der Brennweite  $f$  und der Basis  $b$  des Stereosystems zu

$$|r_1| = \frac{bf}{d}. \quad (4.29)$$

Da der Unterschied der Entfernungen  $|r_1|$  und  $|r_2|$  im Verhältnis von Höhe  $h$  und Entfernung  $|r_1|$  sehr klein ist, gilt die vereinfachenden Annahme, dass die Entfernungen  $|r_1|$  und  $|r_2|$  gleich sind ( $r := r_2 := r_1$ ). Damit ergibt sich die gesuchte Höhe  $h$  des Punktes  $P$  aus dem Kosinussatz:

$$h = \sqrt{2r^2 - 2r^2 \cos \alpha}. \quad (4.30)$$

Abbildung 4.15 zeigt die entstandene Höhenkarte. Farblich kodiert gibt sie die Höhe eines Punktes relativ zum Fahrbahniveau in dieser Entfernung an.

### 4.3 Implementierung

Das beschriebene Verfahren ist vollständig in C++ implementiert. Die einzelnen Module sind streng in Klassen unterteilt und besitzen definierte Schnittstellen. Dies gewährleistet eine einfache Modifizier- und Erweiterbarkeit des Algorithmus.

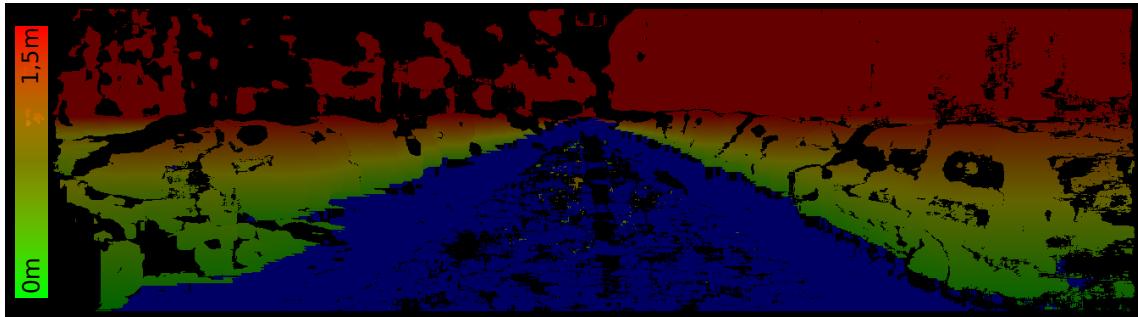


Abbildung 4.15: Höhenkarte.

Parallelisierbare Berechnungsabläufe innerhalb der Module sind mit der Compiler-Erweiterung für Datenparallelität *OpenMP*<sup>1</sup> optimiert. Auf Grund der Datenparallelität bei der Erstellung und Filterung der V-Disparität ist dieses Modul außerdem durch Vektorisierung, unter Verwendung der Befehlssatzerweiterung SSE, optimiert.

Die grundlegende Datenstruktur der Bilder und Matrizen sowie einige rudimentäre Bildbearbeitungsfunktionen entstammen der Bildbearbeitungsbibliothek *OpenCV*<sup>2</sup>. Diese bietet außerdem alle benötigten algebraischen Operationen inklusive eines *Least-Squares-Solvers* unter Verwendung der Singulärwertzerlegung.

Das benötigte Disparitätsbild wird durch die *ToastlibMulticore* [RSK11] erzeugt. Diese ist ein lokaler Block-Matcher mit eingebauter Validierung der gefundenen Punktkorrespondenzen durch einen Links-Rechts-Abgleich und einen Texturfilter. Das Verfahren ist echtzeitfähig und liefert Bilder bis zu 30Hz.

Zur Eigenbewegungsschätzung wird die *Libviso2* [GZS11] verwendet. Die *Libviso2* schätzt die Eigenbewegung zwischen zwei aufeinander folgenden Stereo-Bildpaaren durch Minimierung des Projektionsfehlers von Punktkorrespondenzen, und basiert damit auf den gleichen Eingangsdaten wie der Stereo-Matcher.

Während die einzelnen Module intern durch Parallelisierung optimiert sind, sind die Module selbst sequentiell angeordnet. Das betrifft sowohl die Module des Fahrbahnschätzers als auch das vorgesetzte Modul des Stereo-Matchers und der Eigenbewegungsschätzung. Abbildung 4.16 stellt die Anordnung der Module dar. Durch eine parallele Anordnung der Module ergibt sich ein großes Optimierungspotential, welches im Ausblick (vgl. Abschnitt 7.2.3) näher betrachtet wird.

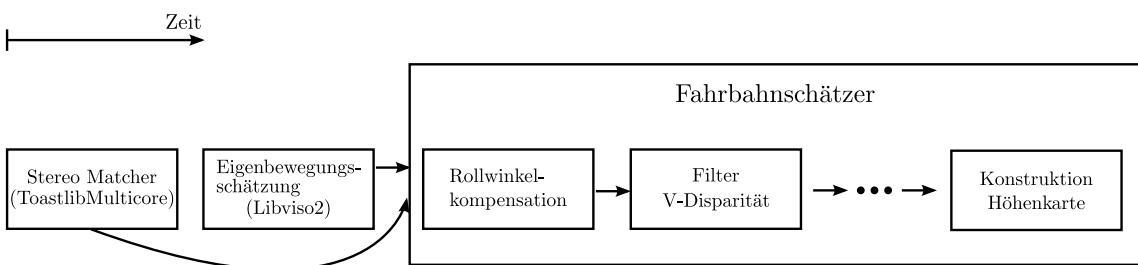


Abbildung 4.16: Sequentielle Anordnung der Module.

<sup>1</sup><http://www.openmp.org>

<sup>2</sup><http://opencv.willowgarage.com>

## 5. Ergebnis

### 5.1 Qualitative Bewertung der Fahrbahnschätzung

Die nachfolgenden Ergebnisse basieren auf Stereo-Bildern von Messfahrten in der Karlsruher Innenstadt, aufgenommen von Mitarbeitern des Instituts für Mess- und Regelungstechnik. Die Daten sind frei Verfügbar und können auf [cvlibs.net<sup>1</sup>](http://cvlibs.net/) heruntergeladen werden. Das verwendete Stereo-Kamerasystem hat eine Auflösung von  $1344 \times 372$  Bildpunkten. Die Basisbreite der beiden Kameras beträgt  $0,57m$  und die Brennweite  $645px$ . Der verwendete Stereo-Matcher ist die *ToastlibMulticore* [RSK11] und erzeugt ein Disparitätenbild im Wertebereich von 0 bis 90.

Abbildung 5.1 zeigt das linke Kamerabild der Fahrzeugumgebung und darin überlagert die erstellte Höhenkarte. Auf Basis der Lookup Tables für das Fahrbahnprofil wird hier außerdem eine einfache Segmentierung der Straße durchgeführt (blau). Alles was innerhalb eines kleinen Toleranzbereichs zum Fahrbahnprofil liegt wird als Fahrbahn markiert.

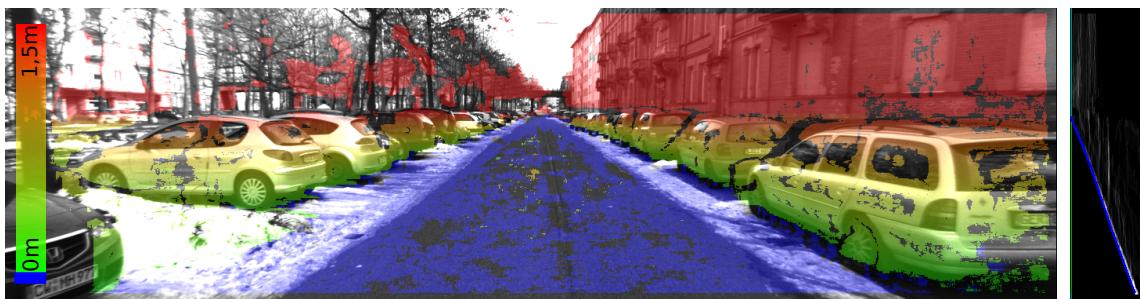


Abbildung 5.1: Höhenkarte mit V-Disparität.

Die Höhenkarte ist relativ zum Fahrbahniveau farblich kodiert. Beginnend bei grün, was gerade dem Toleranzbereich der Fahrbahnsegmentierung entspricht, verläuft das Höhenprofil kontinuierlich bis zu einer Höhe von  $1,5m$  (rot). Alles was darüber liegt ist ebenfalls in rot kodiert. Die Lücken in Abbildung 5.1 sind Punkte, für die der Stereo-Matcher keine Punktcorrespondenz, und damit keine Disparität, ermitteln konnte.

Rechts der Höhenkarte ist die V-Disparität dargestellt und darin das geschätzte Fahrbahnprofil (blau).

<sup>1</sup><http://cvlibs.net/datasets.html>

Abbildung 5.2 zeigt ein Szenario in dem der Fahrbahnverlauf einen plötzlichen Knick macht. Die Fahrbahn verläuft zunächst aufwärts und knickt dann auf der Brücke ab und verläuft horizontal nach hinten.

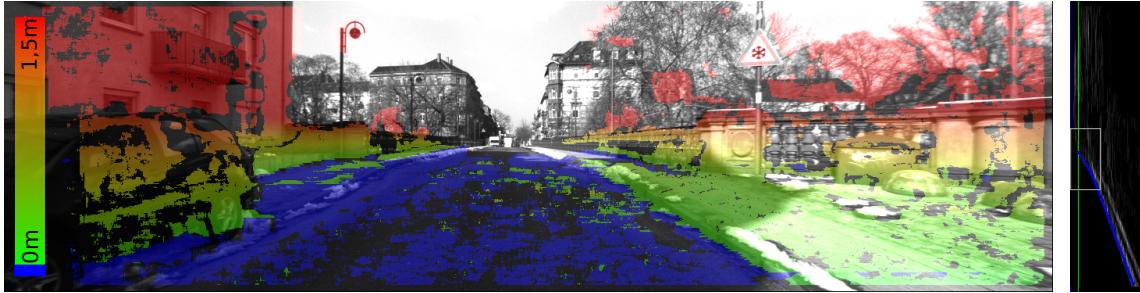


Abbildung 5.2: Abknickender Fahrbahnverlauf.

Der grau umrahmte Ausschnitt der V-Disparität ist nochmals, zusammen mit dem entsprechenden Ausschnitt der Höhenkarte, vergrößert in Abbildung 5.3 dargestellt. Die senkrechte grüne Linie markiert die maximale Entfernung für das Fahrbahnmodell gültig ist. Die rot gestrichelt Gerade kennzeichnet außerdem eine hypothetische lineare Fahrbahnschätzung.

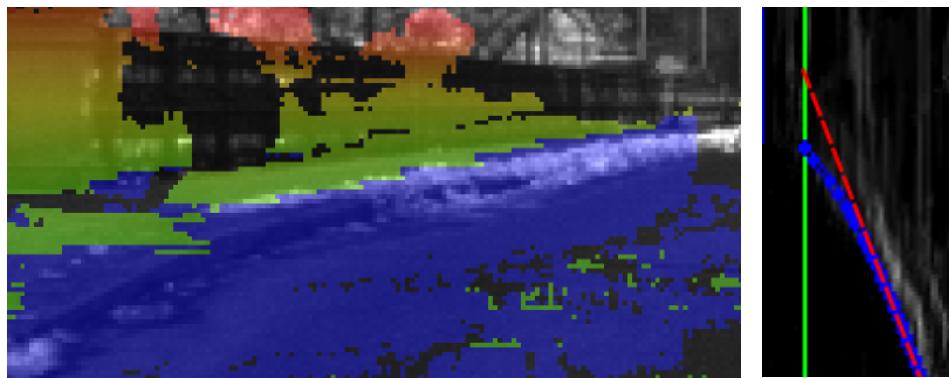


Abbildung 5.3: Ausschnitt der V-Disparität mit spline-förmigen (blau) und linearem (rot) Fahrbahnverlauf.

Die Korrektheit des geschätzten Modells lässt sich neben der Lage der Spline in der V-Disparität vor allem mit Hilfe der Höhenkarte verifizieren. Würde man dem linearen Fahrbahnverlauf folgen würde die Fahrbahn am Knick weiter nach oben laufen und alle Punkte entsprechend blau färben. Stattdessen erkennt man, dass die Fahrbahn ebenfalls einen Knick macht und deutlich vom Gehweg abgegrenzt wird. Ebenfalls schön zu sehen ist die konstante Höhe des rechten Brückengeländers entlang der Brücke in Abbildung 5.2, was eindeutig den abgeknickten horizontalen Verlauf des Fahrbahnprofils zeigt.

Den gegenteiligen Verlauf der Fahrbahn zeigt Abbildung 5.4. Hier ist im hinteren Bereich eine Anhöhung der Fahrbahn zu erkennen, was vom Modell deutlich abgebildet wird. Bei der Annahme einer ebenen Fahrbahn würde diese Erhöhung als Hindernis erfasst werden.

Ein ähnliches Ergebnis zeigt Abbildung 5.5. Hier erkennt man ebenfalls die Erhöhung der Fahrbahn und die korrekte Abbildung durch das Modell.

Die Eingangsdaten stammen von einer Motorradmessfahrt bei der die Kameras auf Höhe des Kühlers (ca. 50cm über Grund) montiert sind. Auf Grund der geringen Höhe des Stereo-Kamerasystems erkennt man, dass die Ergebnisse des Stereo-Matchers deutlich schlechter ausfallen als bei der vorherigen Messfahrt. Es wurden viel weniger und verrausachte Punkt-korrespondenzen, ins Besondere auf der Fahrbahn, gefunden. Entsprechend schlechter sieht

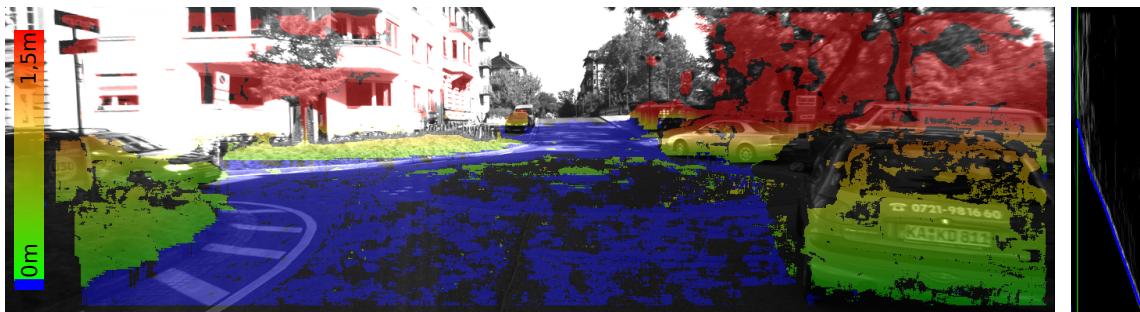


Abbildung 5.4: Erhöhung des Fahrbahnverlaufs.

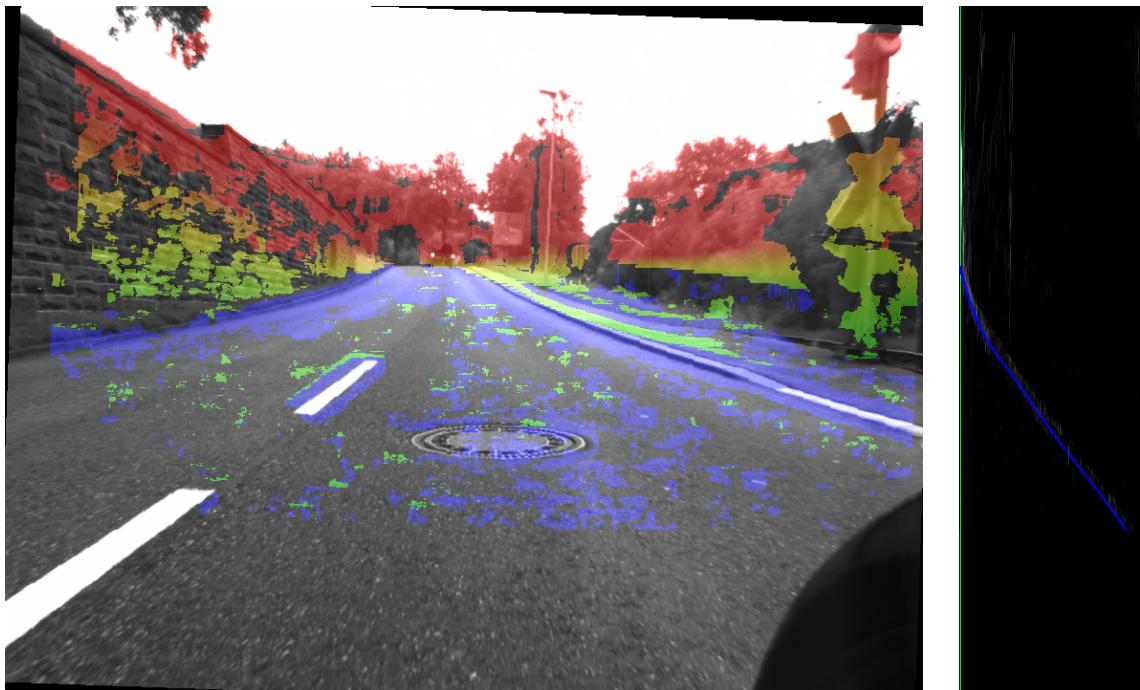


Abbildung 5.5: Erhöhung des Fahrbahnverlaufs.

die V-Disparität aus.

Das Verfahren erweist sich hier allerdings als sehr robust und schätzt auch bei den verhältnismäßig schlechten Eingangsdaten den Fahrbahnverlauf recht gut.

### 5.1.1 Rollwinkelkompensation

Abbildung 5.6 zeigt das Ergebnis der Fahrbahnschätzung mit integrierter Rollwinkelkompensation. Zunächst wird der Neigungswinkel des Motorrads auf  $18^\circ$  bestimmt. Entsprechend werden alle Eingangsdaten gedreht und dann dem ursprünglichen Algorithmus zugeführt. Auch hier erweist sich das Verfahren als robust. Obwohl kaum Punktcorrespondenzen auf der Fahrbahn gefunden wurden, und die V-Disparität sehr verrauscht ist schätzt das Verfahren ein verwertbares Fahrbahnprofil.

## 5.2 Laufzeituntersuchung

Der nachfolgende Benchmark vergleicht die sequentielle Laufzeit des Algorithmus mit einer mit *OpenMP*<sup>2</sup> parallelisierten Version auf zwei 4-Kern Prozessoren. Die genaue Spezifikation des Testsystems ist in Tabelle 5.1 aufgelistet.

<sup>2</sup><http://www.openmp.org>

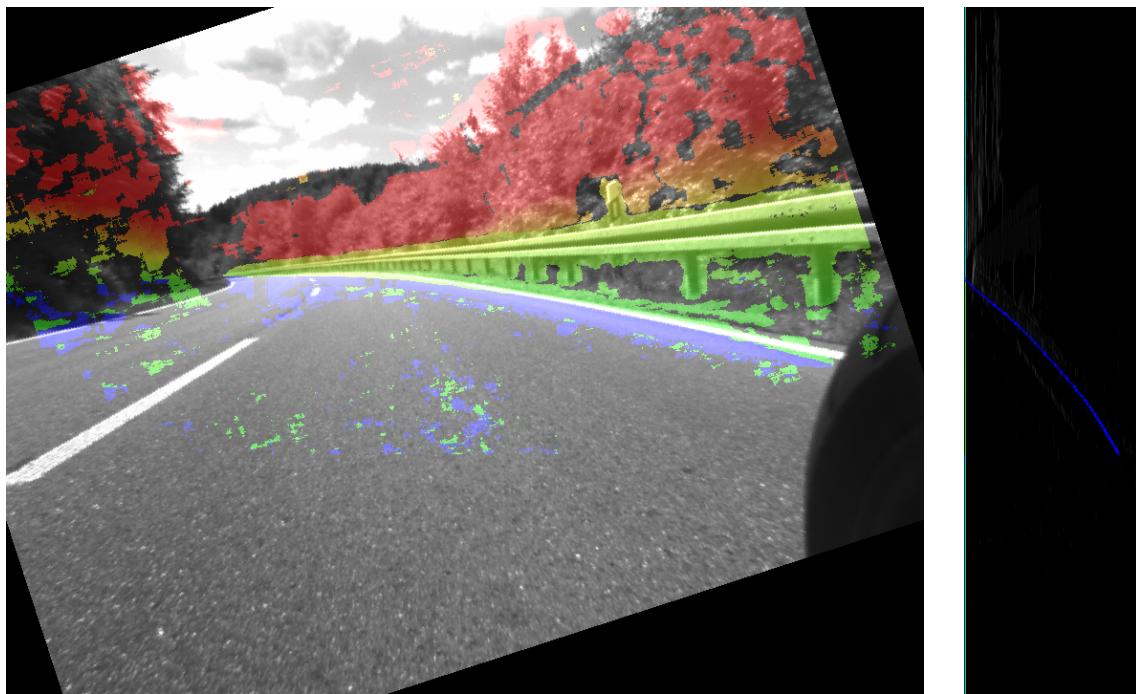


Abbildung 5.6: Rollwinkelkompensierte Schätzung des Fahrbahnverlaufs.

Anzahl Kerne	2x4
CPUs	2x Intel Xeon E5410
Taktfrequenz	2,33 GHz
Arbeitsspeicher	4 GB
Betriebssystem	Ubuntu 11.04
Kernel	Linux 2.6.38-10-generic-pae
Compiler	g++ 4.5.3-3
Optimierung	-O3 -fopenmp -march=native
OpenCV Version	2.3

Tabelle 5.1: Spezifikation des Testsystems.

Tabelle 5.2 enthält die Laufzeiten für ein einzelnes Frame für jedes Modul sowie die Gesamtlaufzeit aller Module. Ermittelt wurden die Werte durch Mittelung aus einer Sequenz mit 484 Bildern.

Die mit (\*) gekennzeichneten Module sind SIMD (SSE/SSE2) optimiert, sowohl in der sequentiellen als auch in der parallelen Variante. Das Modul *Sonstiges* beinhaltet die Initialisierung der Module sowie das Einlesen und Konvertieren der Ursprungs- und Disparitätsbilder.

Die hier verwendete Kamera liefert Bilder mit  $10Hz$ . Die gemittelte Laufzeit für die komplette Verarbeitungskette der Fahrbahnschätzung (ohne Stereo-Matching und Eigenbewegungsschätzung) beträgt  $94ms$  und liegt damit im Bereich der Echtzeitfähigkeit.

Abbildung 5.7 zeigt nochmals die Verteilung der Laufzeiten für die parallele Variante mit 8 Kernen in einem Kuchendiagramm.

### 5.2.1 Laufzeituntersuchung nach dem Amdahlschen Gesetz

Das Amdahlsche Gesetz erlaubt die theoretische Abschätzung der maximalen Beschleunigung der Laufzeit eines Programms (*Speedup*) durch Parallelisierung. Amdahl argumentiert, dass die maximale Beschleunigung eines Programms durch seinen sequentiellen An-

	sequentiell		parallel		Speedup
	Laufzeit [ms]	%-Anteil [%]	Laufzeit [ms]	%-Anteil [%]	
<b>Gesamlaufzeit aller Module</b>	<b>146,7</b>	<b>100</b>	<b>94,0</b>	<b>100</b>	<b>1,6</b>
Filter Fahrkorridor	1,8	1,2	2,6	2,8	0,7
Berechnung U-Disparität	5,4*	3,7	2,1*	2,2	2,6
Vertikaler Hindernisfilter	15,4	10,5	7,4	7,9	2,1
Berechnung V-Disparität	3,4*	2,3	1,2*	1,3	2,7
Threshold V-Disparität	0,8	0,5	0,8	0,9	1,0
Gewichtung V-Disparität	1,9*	1,3	4,1*	4,3	0,5
M-Estimator	3,1	2,1	5,2	5,5	0,6
Kalman Filterung	20,4	13,9	20,5	21,9	1,0
Bestimmung des Fahrbahnprofils	1,4	1,0	2,7	2,9	0,5
Erstellung der Höhenkarte	58,8	40,0	14,2	15,2	4,1
Sonstiges	34,2	23,3	33,0	35,1	1,0

Tabelle 5.2: Gemittelte Laufzeiten für ein Frame.

\* SIMD optimiert

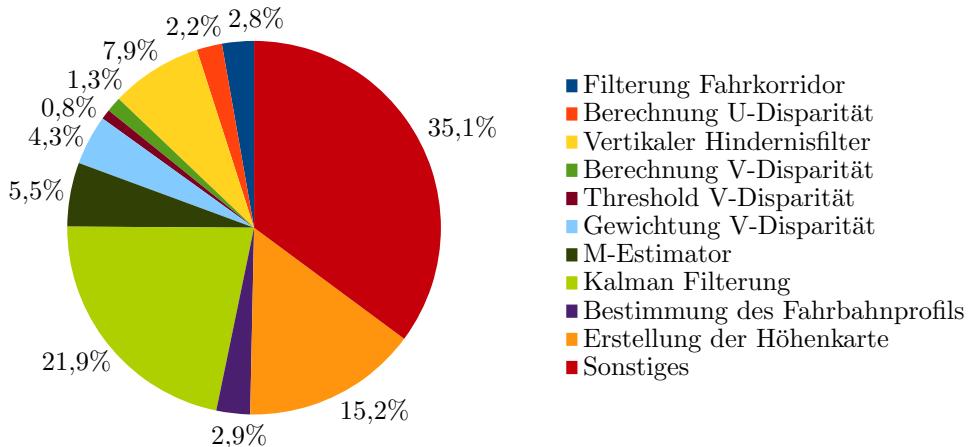


Abbildung 5.7: Prozentuale Verteilung der Laufzeit der Module mit 8 Kernen.

teil, also den nicht parallelisierbaren Teil, begrenzt wird.

Zur Bestimmung des maximalen Speedups wird die Laufzeit prozentual zerlegt, in einen sequentiellen Anteil und den Anteil der sich parallelisieren lässt.

Sei  $P$  der prozentuale parallele Anteil und  $N$  die Anzahl der verwendeten Prozessoren, so ergibt sich der Speedup  $S$  nach Amdahl zu:

$$S = \frac{1}{(1 - P) + \frac{P}{N}}. \quad (5.1)$$

Dabei ist die Differenz  $1 - P$  der sequentielle Anteil und der Quotient  $\frac{P}{N}$  der beschleunigte parallele Anteil des Programms. Mit steigender Prozessoranzahl ergibt sich damit der theoretisch maximal erreichbare Speedup:

$$S_{max} = \lim_{N \rightarrow \infty} \frac{1}{(1 - P) + \frac{P}{N}} = \frac{1}{1 - P}. \quad (5.2)$$

Abbildung 5.8 zeigt das Amdahlsche Gesetz beispielhaft für unterschiedliche parallele Anteile eines Programms. Man erkennt die asymptotische Annäherung des Speedups an seinen

Grenzwert bei steigender Prozessorzahl. Ein höherer Speedup ist nur durch Erweiterung des parallelen Rechenanteils erreichbar, insofern dies möglich ist.

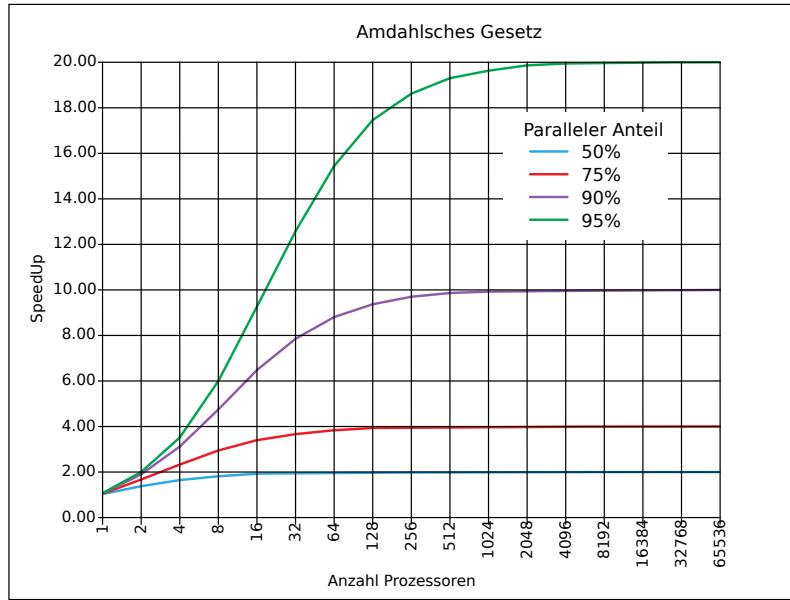


Abbildung 5.8: Amdahlsches Gesetz.  
(Quelle: <http://en.wikipedia.org/wiki/File:AmdahlsLaw.svg>)

Für die Fahrbahnschätzung ergeben Laufzeitmessungen einen parallelen Anteil von ca. 60%. Für das in Tabelle 5.1 spezifizierte Testsystem mit 8 Kernen folgt aus Gleichung 5.1 ein theoretischer Speedup von

$$S = \frac{1}{0,4 + \frac{0,6}{8}} = 2,1. \quad (5.3)$$

Da die verwendeten Kerne geteilte Ressourcen (z.B. den Arbeitsspeicher) benutzen, ist der in der Praxis erreichte Speedup von 1,6 (vgl. Tabelle 5.1) als gut zu bewerten.

Der maximal erreichbare Speedup für die Berechnung eines einzelnen Frames nach dem Amdahlschen Gesetz aus Gleichung 5.2 liegt bei

$$S_{max} = \frac{1}{1 - 0,6} = 2,5. \quad (5.4)$$

### 5.3 Bewertung

Das im Zuge dieser Diplomarbeit entstandene Verfahren zur Modellierung des Fahrbahn-Längsprofils hat sich als geeignet erwiesen. Es ist echtzeitfähig und hat seine Leistungsfähigkeit und Robustheit in Videosequenzen mehrerer Testfahrten unter Beweis gestellt.

Durch die Verwendung der V-Disparität wird die Fahrbahn in kameranahen Koordinaten modelliert. Es ist somit keine Koordinatentransformation notwendig die weitere Modellierungsschritte mit sich ziehen würde. Die Ausgangsdaten der Fahrbahnschätzung liegen, ebenso wie die Eingangsdaten, in Kamerakoordinaten vor und ermöglichen somit eine einfache Weiterverarbeitung.

Auf Grund der Zusammenfassung aller Bildspalten des Disparitätenbildes in der V-Disparität, ist die Datenmenge darin relativ klein und ermöglicht so eine effiziente Umsetzung.

Durch die Anwendung der Heuristiken über die Lage der Fahrbahn in der V-Disparität kommt das Verfahren selbst mit sehr verrauschten und lückenhaften Eingangsdaten zurecht. Auch bei sehr wenigen Matches auf der Fahrbahn bekommen diese dadurch ein

hohes Gewicht und bieten somit die Grundlage für die nachfolgenden Schätzverfahren. Die robuste Detektion und Entfernung von vertikalen Flächen unterstützt dieses Verfahren.

Das der Fahrbahnschätzung zugrunde liegende B-Spline Modell eignet sich zur Modellierung des Fahrbahn-Längsprofils. Das Modell ist mathematisch einfach zu fassen und flexibel genug, um alle realen Fahrbahnverläufe abilden zu können. Durch die kompakte Darstellung des Modells mit Hilfe der *de Boor* Punkte erhält man einen einfachen Zustandsvektor für die Modellparameter.

Begrenzt wird das Modell lediglich durch die Auflösung der Kameras und die größeren Unsicherheiten bei der Suche von Punktkorrespondenzen in großen Entfernungen.

Das für die Zustandsschätzung zuständige Kalman Filter liefert eine robuste und stetige Repräsentation des Fahrbahnprofils. Zusammen mit den Gewichten des M-Estimators beschreibt der geschätzte Spline auch in schwierigen Szenarien das tatsächliche Fahrbahnprofil sehr gut. Die Kalman-Prädiktion mit Verwendung der Eigenbewegungsschätzung bietet außerdem den Vorteil, dass die gesamte Fahrzeugdynamik darin abgebildet wird, ohne dass diese explizit modelliert werden muss.

## 6. Zusammenfassung

Das in dieser Arbeit vorgestellte Verfahren modelliert das Fahrbahn-Längsprofil in Echtzeit und erstellt darauf aufbauend eine Höhenkarte relativ zum Fahrbahnniveau.

Die Fahrbahnschätzung benötigt dazu zwei Eingangsdaten, ein Disparitätenbild und eine Eigenbewegungsschätzung.

Aus dem Disparitätenbild wird die V-Disparität erstellt, und darin das Fahrbahnprofil modelliert. Um möglichst alle Punkte, die nicht zur Fahrbahn gehören, zu entfernen, wird die V-Disparität zunächst gefiltert. Unter Beachtung des aktuellen Fahrzustands werden Punkte außerhalb des Fahrkorridors verworfen. Außerdem werden unter Verwendung der U-Disparität Hindernisse detektiert und ebenfalls verworfen.

Die so erstellte V-Disparität wird weiterhin mit Hilfe zweier Heuristiken, die eine Aussage über die Lage der Fahrbahn innerhalb der V-Disparität treffen, gefiltert. Das Ergebnis der Filterung ist eine feine Linie in der V-Disparität die die Fahrbahn repräsentiert, und im Folgenden vom Modell abgebildet werden soll.

Als Modell dient eine B-Spline-Kurve bestehend aus uniformen kubischen B-Splines. Die Form der B-Spline-Kurve lässt sich durch seine *de Boor* Punkte, welche den Zustandsvektor des Modells bilden, vollständig beschreiben.

Zunächst erhalten die Messpunkte aus der gefilterten V-Disparität mit Hilfe des M-Estimators ein Gewicht entsprechend ihrer Modellgüte. Darauf aufbauend wird dann unter Verwendung eines Kalman Filters der Zustandsvektor des Fahrbahnmodells geschätzt. Für die Prädiktion innerhalb des Kalman Filters werden Fahrbahnpunkte mit Hilfe der Eigenbewegungsschätzung transformiert und so der Zustandsvektor prädiziert.

Aus dem entstandenen Modell wird eine Höhenkarte, relativ zum Fahrbahnniveau, konstruiert. Diese stellt eine intuitive Darstellung der Ergebnisse dar und bildet so die Grundlage weiterer Funktionsentwicklungen.

# 7. Ausblick

Der nachfolgende Abschnitt 7.1 zeigt Probleme des bisherigen Verfahrens auf und nennt einige konkrete Lösungsvorschläge. In Abschnitt 7.2 werden dann grundlegende Möglichkeiten vorgestellt, um das Verfahren zu verbessern und zu optimieren.

## 7.1 Verbesserungspotentiale

### 7.1.1 Erweiterung der Filter für die V-Disparität

Die Heuristiken zur Filterung der V-Disparität haben sich grundsätzlich bewährt. Auf Grund ihrer Semantik sind sie allerdings anfällig für fehlerhafte Eingangsdaten.

Das Problem liegt in der großen Gewichtung von Punkten die zu weit links und/oder unten in der V-Disparität, und damit unterhalb der tatsächlichen Fahrbahn, liegen (vgl. Abschnitt 4.2.4).

Um dieser Problematik zu begegnen wird das *95%-Kriterium* auf die zugeordneten Gewichte angewandt. Dieses bringt eine deutliche Steigerung der Robustheit gegenüber wenigen Messfehlern. Allerdings kann dieses Kriterium Messfehler nur begrenzt kompensieren. Sobald sich innerhalb einer Bildzeile oder Spalte 6% der Messungen fehlerhaft unterhalb der tatsächlichen Fahrbahnlinie anhäufen, kann sich das maximale Gewicht der Filterung deutlich verschieben. Und mit der Verschiebung des Gewichts verschiebt sich auch die Annahme über die Lage der Fahrbahn in der V-Disparität. Bleibt diese fehlerhafte Messanhäufung über mehrere Bilder bestehen, kann auch die Trägheit des Kalman Filters den Modellfehler nicht mehr abfangen.

Abbildung 7.1 zeigt die V-Disparität mit einer fehlerhaften Messanhäufung im linken unteren Eck über mehrere Bilder. Als Ergebnis wird der Spline an dieser Stelle herunter gezogen und liefert ein fehlerhaftes Fahrbahnprofil. Es sei hier allerdings angemerkt, dass das Fahrbahnmodell an der Stelle an der der Spline die Fahrbahnlinie verlässt abgeschnitten wird, und das Gesamtergebnis deshalb lediglich einen sehr kurzen Fahrbahnverlauf modelliert.

Um den Einfluss der genannten Messfehler vollständig und robust entfernen zu können muss die V-Disparität vor der Auswertung der Heuristiken nochmals gefiltert werden. Während Messfehler oberhalb der Fahrbahn automatisch an Einfluss verlieren, werden Messfehler unterhalb verstärkt. Aus diesem Grund sollte das Filter so konzipiert sein, dass es Messpunkte unterhalb der Fahrbahn entfernt.

Ein denkbarer Ansatz ist das vorläufige Schätzen einer Geraden in der V-Disparität. Anschließend werden dann alle Punkte unterhalb eines Toleranzbereichs zu dieser Geraden



Abbildung 7.1: Fehlerhafte Gewichtung der V-Disparität auf Grund von Messfehlern.

vollständig entfernt.

Ein weiterer Ansatz ist das Finden und Entfernen von Punkten bzw. Punktanhäufungen im linken unteren Bildbereich mit Hilfe Bildverarbeitender Methoden. Mit den Werkzeugen *Erosion* und *Dilatation* lassen sich beispielsweise alleinstehende Punkte bzw. Anhäufungen entfernen.

### 7.1.2 Kalman Prädiktion auch beim Abbiegen

Die in Abschnitt 4.2.7 beschriebene Prädiktion des Fahrbahnprofils bei der Kalman Filterung ist nur dann gültig, solange man die gleiche Fahrbahn betrachtet. Sobald man an einer Kreuzung auf eine andere Straße abbiegt ist es offensichtlich falsch die neue Fahrbahn aus der alten heraus zu prädizieren. Deshalb wird bisher beim Abbiegen das Kalman Filter ausgesetzt und durch die Zustandsschätzung des M-Estimators ersetzt.

Neben einem vollständig neuen Ansatz für den Prädiktionsschritt des Kalman Filters der in Abschnitt 7.2.2 angesprochen wird, ist auch ein Ansatz denkbar, der dem jetzigen Verfahren ähnlich ist aber nicht dem Problem beim Abbiegen unterliegt.

Anstatt Punkte der alten Fahrbahn zu prädizieren werden dabei die Punkte der Umgebung prädiziert und daraus eine prädizierte Fahrbahnschätzung erstellt.

Dazu werden alle Punkte des Disparitätenbildes mit der Eigenbewegungsschätzung prädiziert. Aus dem so prädizierten Disparitätenbild kann dann eine prädizierte V-Disparität erstellt werden. Die gesamten Filtermethoden der V-Disparität sowie der M-Estimator Schritt können dann auf die prädizierte V-Disparität angewendet werden, um so eine Prädiktion für das Fahrbahnprofil zu erhalten.

Im Gegensatz zum bisherigen Verfahren wird so die prädizierte Fahrbahn aus einer prädizierten Umwelt gewonnen und nicht aus der alten Fahrbahn bestimmt. Während des Abbiegemanövers gewinnt so die neue Fahrbahn sukzessive an Einfluss, während der der alte Fahrbahn abnimmt.

Auch dieses Verfahren entspricht nicht der klassischen Kalman Prädiktion, ist aber, gegenüber dem bisherigen Verfahren, auch beim Abbiegen einsetzbar. Auf Grund des deutlich höheren Aufwands der hier beschriebenen Fahrbahnprädiktion ist allerdings mit einer deutlich höheren Laufzeit zu rechnen.

## 7.2 Mögliche Weiterentwicklung

### 7.2.1 Weiche Übergänge statt Grenzwerte im Disparitätenbild

Bisher werden alle Punkte des Disparitätenbildes gleich behandelt. Neben dem Disparitätenbild gibt die *ToastlibMulticore* allerdings für jede gefundene Punktcorrespondenz (für jeden Punkt im Disparitätenbild) einen Wert für die Vertrauenswürdigkeit dieses Punktes an. Durch die Beachtung dieser Faktoren würden Punkte mit kleiner Vertrauenswürdigkeit an Einfluss verlieren und die Punkte, die mit sehr großer Wahrscheinlichkeit korrekt sind stärker gewichtet. Dadurch ist eine erhöhte Robustheit des Verfahrens zu erwarten.

Neben dem Disparitätenbild sind auch die beiden darauf angewendeten Filter binär. Das Filter des Fahrkorridors entfernt alle Punkte vollständig die außerhalb der Grenzen des Fahrkorridors liegen. Gleichermassen entfernt das Filter für die vertikalen Flächen alle Punkte vollständig aus dem Disparitätenbild, die sich zusammen in der U-Disparität über einem bestimmten Grenzwert abbilden. Für beide Filter ist, anstelle eines harten Grenzwerts, ein weicher Übergang denkbar, der den Punkten in den Grenzbereichen ein entsprechendes Gewicht zuordnet.

### 7.2.2 Modellierung der Systemdynamik für das Kalman Filter

Um der eigentlichen Kalman Prädiktion folgen zu können und sich den aufwändigen Umweg über die Fahrzeugkoordinaten zu sparen muss man die Dynamik des Systems in der V-Disparität kennen. Idealerweise kennt man dazu die Übergangsmatrix  $\mathbf{A}$  für den Zustandsübergang in Bildkoordinaten:

$$\mathbf{x}_{k+1} = \mathbf{A}_k \mathbf{x}_k + \mathbf{w}_k. \quad (7.1)$$

Auf diese Weise kann der neue Zustandsvektor einfach prädiziert werden und die Varianz der Schätzung gemäß Gleichung 3.46 bestimmt werden.

Durch kurze Recherchen und Überlegungen zu Beginn der Diplomarbeit konnten jedoch keine Ansätze zur Bestimmung der Übergangsmatrix gefunden werden. Ähnliche Ansätze wie die von Daimler [WBR<sup>+</sup>09] geben ebenfalls keine Systemdynamik an und ersetzen den klassischen Prädiktionsschritt durch Minimierung des Fehlers zwischen dem alten und neuen Fahrbahnmodell.

Aus diesem Grund ist zunächst einmal zu überprüfen, ob überhaupt ein allgemeines Modell für den Zustandsübergang existiert, oder zumindest eine Vorschrift zur Bestimmung der Systemmatrix  $\mathbf{A}_k$  für den aktuellen Zeitschritt gefunden werden kann.

### 7.2.3 Optimierung durch weitergehende Parallelisierung

Während die einzelnen Module intern durch Parallelisierung optimiert sind, sind die Module der Fahrbahnschätzung sowie das Modul des Stereo-Matchers und der Eigenbewegungsschätzung gemäß Abbildung 4.16 sequentiell angeordnet. Durch die mögliche parallele Anordnung einiger Module ergibt sich ein großes Optimierungspotential hinsichtlich der Laufzeit des Verfahrens.

Die Geschwindigkeit des Algorithmus lässt sich durch zwei Kenngrößen ausdrücken, die Bildrate  $fr$  und die Latenz  $t_l$ . Die Bildrate gibt die Anzahl der Eingangsbilder pro Sekunde an, die vollständig verarbeitet werden können, und die gesamte Verarbeitungskette durchlaufen. Die Latenz hingegen gibt an, wie hoch die Verarbeitungszeit für ein einzelnes Eingangsbild ist, bis es die gesamte Verarbeitungskette durchlaufen hat.

Während bei der sequentiellen Anordnung der Module die beiden Kenngrößen antiproportional zueinander sind, sind die beiden Größen bei der Parallelisierung getrennt zu betrachten und wohl zu unterscheiden.

[RSK11] führt die Größe der *maximalen Perceptions-Latenz*  $t_{MPL}$  ein. Diese kombiniert die Bildrate mit der Latenz und beschreibt die maximale Dauer zwischen Ereignis und Erfassung dieses Ereignisses durch eine Anwendung. Tritt ein Ereignis genau dann ein, wenn ein Bild gerade aufgenommen wurde, setzt sich die maximale Perzeptions-Latenz aus der Dauer bis zur nächsten Aufnahme eines Bildes und der Latenz zur Verarbeitung dieses Bildes zusammen:

$$t_{MPL} = \frac{1}{fr} + t_l. \quad (7.2)$$

### 7.2.3.1 Parallele Ausführung unabhängiger Module

Module, die auf den gleichen Eingangsdaten arbeiten und unabhängig voneinander sind, können parallel ausgeführt werden. Durch die parallele Anordnung ergibt sich eine kürzere Laufzeit des Algorithmus. Dadurch steigt die Bildrate bzw. fällt gleichermaßen die Latenz. Unabhängig sind zunächst beide Module zur Berechnung der Eingangsdaten für den Fahrbahnschätzer, der Stereo-Matcher und die Eigenbewegungsschätzung. Beide arbeiten auf den gleichen Eingangsdaten und sind komplett unabhängig voneinander. Sie können daher problemlos parallel nebeneinander laufen.

Innerhalb der Fahrbahnschätzung können außerdem, ohne großen Aufwand, die Module zur Filterung des Disparitätenbildes parallelisiert werden. Die Filterung des Fahrkorridors sowie das Entfernen vertikaler Flächen mit Hilfe der U-Disparität ist unabhängig voneinander. Lediglich das Ergebnis beider Filter muss in einem neuen Disparitätenbild Und-Verknüpft vereinigt werden.

Die sich daraus ergebende, teilweise parallele Anordnung der Module ist in Abbildung 7.2 dargestellt.

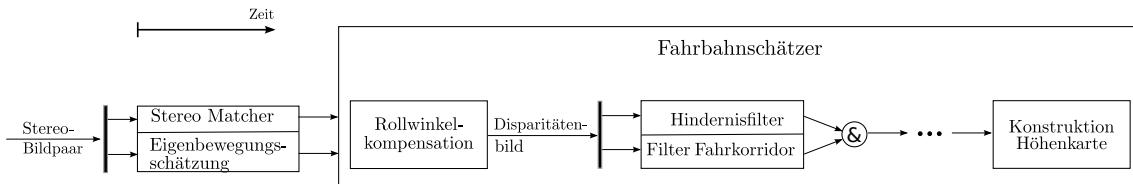


Abbildung 7.2: Parallele Anordnung der Module.

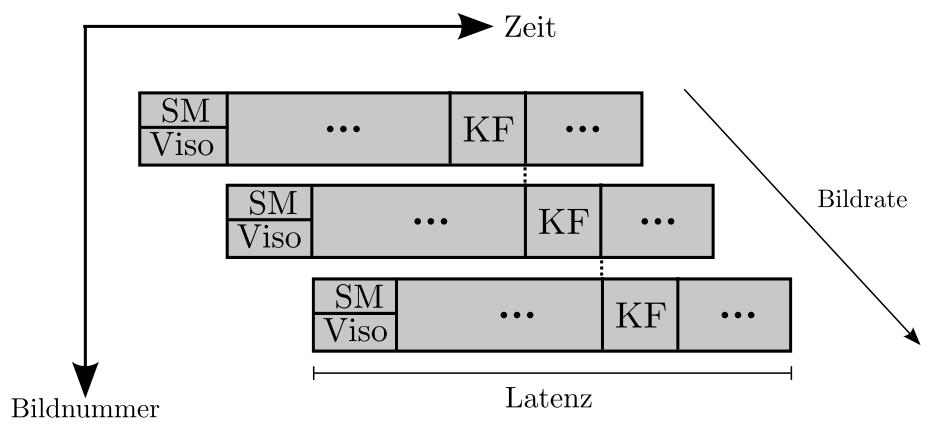
### 7.2.3.2 Überlagerung der Verarbeitungskette

Die meisten der Module des Fahrbahnschätzers sind abhängig von den Ausgangsdaten des vorherigen Moduls und können so innerhalb der Verarbeitungskette nicht parallel zueinander ausgeführt werden.

Um die Bildrate dennoch weiter zu steigern kann die gesamte Verarbeitungskette jedoch auf mehreren Bildfolgen parallel rechnen. Das bedeutet, dass die Verarbeitung eines Bildes sofort beginnt sobald es zur Verfügung steht, und nicht wie bisher erst dann, wenn das aktuelle Bild vollständig verarbeitet ist.

Auf diese Weise lässt sich die Bildrate erhöhen, allerdings bleibt die Latenz für die vollständige Abarbeitung eines Bildes bestenfalls gleich, da dazu immer noch die gesamte Verarbeitungskette durchlaufen werden muss.

Neben der elementaren Grenzen der Überlagerung der Verarbeitungskette durch die Bildrate der Kamera, wird die Grenze durch das Kalman Filter bestimmt. Da das Kalman Filter zur Prädiktion die Schätzung der Fahrbahn aus dem vorherigen Bild benötigt, kann sie erst dann erfolgen, wenn die Kalman Filterung des vorherigen Bildes abgeschlossen ist. Die Überlagerung der Verarbeitungskette ist in Abbildung 7.3 dargestellt. Zur übersichtlicheren Darstellung ist die gesamte Verarbeitungskette aus Abbildung 7.2 in einem Balken zusammengefasst. Die Grenzen der Überlagerung durch das Kalman Filter ist darin zu beachten.



(SM: Stereo-Matcher, Viso: Eigenbewegungsschätzung, KF: Kalman Filter)

Abbildung 7.3: Überlagerung der Verarbeitungskette.

# Verwendete Symbole

Symbol	Einheit	Beschreibung
$A$	-	Übergangsmatrix
$b$	$m$	Basisbreite des Stereo-Kamerasystems
$c$	-	<i>de Boor</i> Punkt
$d$	$px$	Disparität eines Punktes
$f$	$px$	Brennweite der Kamera ausgedrückt in Pixeln
$fr$	$\frac{1}{s}$	Bildrate
$h$	$m$	Höhe eines Punktes
$H$	-	Beobachtungsmatrix
$H^*$	-	Gewichtete Beobachtungsmatrix
$I_d$	-	Integralbild entlang der Bildspalten
$I_v$	-	Integralbild entlang der Bildzeilen
$N_i$	-	Basisfunktion der uniformen kubischen B-Splines
$\hat{P}^-$	-	Kovarianz der Kalman-Prädiktion
$\hat{P}^+$	-	Kovarianz der Kalman-Korrektur
$R$	$m$	Kurvenradius
$S$	-	B-Spline
$S$	-	Speedup
$t$	-	Kurvenparameter des B-Splines
$t_l$	$s$	Latenz der Verarbeitungskette
$T$	-	Transformationsmatrix der Eigenbewegungsschätzung
$T$	-	Knotenvektor der Spline-Kurve
$u$	$px$	Index der Bildspalten
$U$	-	Helligkeitswert eines Punktes in der U-Disparität
$v$	$px$	Index der Bildzeilen
$v$	$\frac{m}{s}$	Geschwindigkeit des Fahrzeugs
$V$	-	Helligkeitswert eines Punktes in der V-Disparität
$W_{A_d}$	-	Gewicht der Heuristik entlang der Bildspalten
$W_{A_v}$	-	Gewicht der Heuristik entlang der Bildzeilen
$W$	-	Transformiertes Gewicht der Heuristiken
$x$	-	Zustandsvektor
$\hat{x}^-$	-	Zustandsvektor der Kalman-Prädiktion
$\hat{x}^+$	-	Zustandsvektor der Kalman-Korrektur
$z$	$m$	Entfernung eines Punktes zur Bildebene
$z$	-	Messvektor
$z^*$	-	Gewichteter Messvektor
$\Phi$	$\circ$	Rollwinkel des Fahrzeugs
$\Psi$	$\frac{rad}{s}$	Gierrate des Fahrzeugs

# Abbildungsverzeichnis

1.1	Ebener und tatsächlicher Fahrbahnverlauf. . . . .	2
1.2	Fahrbahnschätzer . . . . .	2
3.1	Erzeugung eines Disparitätenbildes. . . . .	6
3.2	Disparitätenbild. . . . .	7
3.3	V-Disparität. . . . .	8
3.4	U-Disparität. . . . .	8
3.5	Ein uniformer kubischer Spline. . . . .	10
3.6	Die vier kubischen Basis-Splines. . . . .	12
3.7	Gewichtungsfunktionen $w(e)$ . . . . .	14
3.8	Zwei Iterationen im <i>M-Estimator</i> . . . . .	15
4.1	Anordnung der Module und ihre Schnittstellen. . . . .	19
4.2	V-Disparität für unterschiedliche Rollwinkel. . . . .	20
4.3	Intensitätsverteilung der V-Disparität. . . . .	20
4.4	Bestimmung des Fahrkorridors. . . . .	21
4.5	Original Disparitätenbild und Histogramme. . . . .	22
4.6	Disparitätenbild und V-Disparität nach Entfernung vertikaler Flächen. . . . .	22
4.7	Anwendung der Heuristiken auf die V-Disparität. . . . .	23
4.8	Integralbilder der V-Disparität. . . . .	24
4.9	Gewichtsverteilung $W_{A_d}$ ohne (links) und mit (rechts) Ausreißern. . . . .	24
4.10	Transformation der Gewichtsverteilung. . . . .	25
4.11	Eine Messung in der V-Disparität. . . . .	25
4.12	Iterative Schätzung der Spline mit dem M-Estimator. . . . .	27
4.13	Prädiktionsschritt des Kalman Filters. . . . .	28
4.14	Konstruktion der Höhenkarte. . . . .	30
4.15	Höhenkarte. . . . .	31
4.16	Sequentielle Anordnung der Module. . . . .	31
5.1	Höhenkarte mit V-Disparität. . . . .	32
5.2	Abknickender Fahrbahnverlauf. . . . .	33
5.3	Ausschnitt der V-Disparität mit spline-förmigen (blau) und linearem (rot) Fahrbahnverlauf. . . . .	33
5.4	Erhöhung des Fahrbahnverlaufs. . . . .	34
5.5	Erhöhung des Fahrbahnverlaufs. . . . .	34
5.6	Rollwinkelkompensierte Schätzung des Fahrbahnverlaufs. . . . .	35
5.7	Prozentuale Verteilung der Laufzeit der Module mit 8 Kernen. . . . .	36
5.8	Amdahlsches Gesetz. (Quelle: <a href="http://en.wikipedia.org/wiki/File:AmdahlsLaw.svg">http://en.wikipedia.org/wiki/File:AmdahlsLaw.svg</a> ) . . . . .	37
7.1	Fehlerhafte Gewichtung der V-Disparität auf Grund von Messfehlern. . . . .	41
7.2	Parallele Anordnung der Module. . . . .	43
7.3	Überlagerung der Verarbeitungskette. . . . .	44

# Literaturverzeichnis

- [AA98] Lane R. A. und Thacker N. A.: *Tutorial: Overview of Stereo Matching Research*. 1998.
- [AG11a] Daimler AG: *Active Brake Assist: Bei Gefahr Vollbremsung*, Mai 2011. <http://www.daimler.com/dccom/0-5-1210220-49-1210349-1-0-0-1210338-0-0-8-7165-0-0-0-0-0-0.html>.
- [AG11b] Daimler AG: *Spurhalte-Assistent: Immer auf der richtigen Spur*, Mai 2011. <http://www.daimler.com/dccom/0-5-1210220-49-1210351-1-0-0-1210338-0-0-8-7165-0-0-0-0-0-0.html>.
- [Ait35] A. C. Aitken: *On Least Squares and Linear Combinations of Observations*. Proceedings of the Royal Society of Edinburgh, 1935.
- [Bar83] Brian A. Barsky: *A Study of the Parametric Uniform B-spline Curve and Surface Representations*. Technischer Bericht UCB/CSD-83-118, EECS Department, University of California, Berkeley, May 1983. <http://www.eecs.berkeley.edu/Pubs/TechRpts/1983/5671.html>.
- [BBB87] R. Bartels, J. Beatty und B. Barsky: *An Introduction to Splines for use in Computer Graphics and Geometric Modeling*, Kapitel 9.2. Morgan Kaufmann Publisher, Inc., 1987, ISBN 0-934613-27-3.
- [CJLL07] Erik Coelingh, Lotta Jakobsson, Henrik Lind und Magdalena Lindman: *Collision Warning with Auto Brake - A Real-Life Safety Perspective*. Technischer Bericht 07-0450, Volvo Car Corporation, 2007.
- [De 01] C. De Boor: *A Practical Guide to Splines*, Kapitel IX, Seite 93. Springer-Verlag New York Berlin Heidelberg, 2001, ISBN 0-387-95366-3.
- [DW00] Hugh Durrant-Whyte: *Equations for the Prediction Stage of the Information Filter*, 2000.
- [Gmb11] Robert Bosch GmbH: *Vorausschauendes Notbremsystem von Bosch in Serie*, Mai 2011. <http://www.bosch-presse.de/presseforum/details.htm?txtID=4570&locale=de>.
- [GZS11] Andreas Geiger, Julius Ziegler und Christoph Stiller: *StereoScan: Dense 3d Reconstruction in Real-time*. In: *IEEE Intelligent Vehicles Symposium*, Baden-Baden, Germany, June 2011.
- [Kha] Mohammad Emtiyaz Khan: *Matrix Inversion Lemma and Information Filter*.
- [LAT02] R. Labayrade, D. Aubert und J. P. Tarel: *Real Time Obstacle Detection on Non Flat Road Geometry through ‘V-Disparity’ Representation*. In: *Proceedings of IEEE Intelligent Vehicle Symposium*, Band 2, Seiten 646–651, Versailles, France, 2002. <http://perso.lcpc.fr/tarel.jean-philippe/publis/iv02.html>.

- [Lex11] Lexus: *Objekterkennungssystem*, Mai 2011. [http://www.lexus.de/range\\_ls/key-features/safety/safety-obstacle-detection.aspx?WT.ac=spotlight\\_Objekterkennungssystem](http://www.lexus.de/range_ls/key-features/safety/safety-obstacle-detection.aspx?WT.ac=spotlight_Objekterkennungssystem).
- [LF10] H. Loose und U. Franke: *B-spline-based road model for 3d lane recognition*. In: *Intelligent Transportation Systems (ITSC), 2010 13th International IEEE Conference on*, Seiten 91 –98, sept. 2010.
- [NDF<sup>+</sup>04] Sergiu Nedevschi, Radu Danescu, Dan Frentiu, Tiberiu Marita, Florin Oniga, Ciprian Pocol, Thorsten Graf und Rolf Schmidt: *High accuracy stereovision approach for obstacle detection on non-planar roads*. In: *in IEEE Intelligent Engineering Systems (INES*, Seiten 211–216, 2004.
- [ONMT07] F. Oniga, S. Nedevschi, M.M. Meinecke und Thanh Binh To: *Road Surface and Obstacle Detection Based on Elevation Maps from Dense Stereo*. In: *Intelligent Transportation Systems Conference, 2007. ITSC 2007. IEEE*, Seiten 859 –865, 30 2007-oct. 3 2007.
- [Rib04] Maria Isabel Ribeiro: *Kalman and Extended Kalman Filters: Concept, Derivation and Properties*, 2004.
- [RSK11] B. Ranft, T. Schoenwald und B. Kitt: *Parallel matching-based estimation - a case study on three different hardware architectures*. In: *Intelligent Vehicles Symposium (IV), 2011 IEEE*, Seiten 1060 –1067, june 2011.
- [Toy11] Toyota: *Toyota's Approach to Safety Technology and Vehicle Development*, Mai 2011. [http://www.toyota-global.com/sustainability/sustainability\\_report/highlights\\_in\\_fy2009\\_social\\_aspects/approach\\_to\\_safety\\_technology\\_vehicle\\_development.html](http://www.toyota-global.com/sustainability/sustainability_report/highlights_in_fy2009_social_aspects/approach_to_safety_technology_vehicle_development.html).
- [vdMG06] W. van der Mark und D.M. Gavrila: *Real-time dense stereo for intelligent vehicles*. Intelligent Transportation Systems, IEEE Transactions on, 7(1):38 –50, march 2006, ISSN 1524-9050.
- [WB95] Greg Welch und Gary Bishop: *An Introduction to the Kalman Filter*. Technischer Bericht, 1995.
- [WBR<sup>+</sup>09] A. Wedel, H. Badino, C. Rabe, H. Loose, U. Franke und D. Cremers: *B-Spline Modeling of Road Surfaces With an Application to Free-Space Estimation*. Intelligent Transportation Systems, IEEE Transactions on, 10(4):572 –583, dec. 2009, ISSN 1524-9050.
- [WW98] Todd A. Williamson und Todd A. Williamson: *A High-Performance Stereo Vision System for Obstacle Detection*. Technischer Bericht, 1998.
- [ZY07] Yi Zhang und Li Yan: *Road surface modeling and representation from point cloud based on fuzzy clustering*. Geo-Spatial Information Science, 10:276–281, 2007, ISSN 1009-5020. <http://dx.doi.org/10.1007/s11806-007-0106-0>, 10.1007/s11806-007-0106-0.